武漢理工大學

（申请工学硕士学位论文）

基于远程监督的实体关系抽取方法研究

培养单位：计算机科学与技术学院

学科专业：软件工程

研 究 生：李 浩

指导教师：刘永坚 教授

2019 年 5 月

基于远程监督的实体关系抽取方法研究

李浩

武汉理工大学

分类号_____ 密　　级_____

UDC _____ 学校代码___10497___

武汉理工大学

学　位　论　文

题　目 基于远程监督的实体关系抽取方法研究

英　文 Research on Entity Relation Extraction Method

题　目 Based on Distant Supervision

研究生姓名 李浩

指导教师 姓名 刘永坚 职称 教授 学位 学士

单位名称 计算机科学与技术学院 邮编 430070

申请学位级别 工学硕士 学科专业名称 软件工程

论文提交日期 2019 年 3 月 论文答辩日期 2019 年 5 月

学位授予单位 武汉理工大学 学位授予日期 2019 年 6 月

答辩委员会主席 邹承明 评阅人 教育部学位中心盲审

教育部学位中心盲审

2019 年 5 月

独 创 性 声 明

本人声明，所呈交的论文是本人在导师指导下进行的研究工作及取得的研究成果。尽我所知，除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得武汉理工大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示了谢意。

签 名：李洁　　日 期：2019.5.20

学位论文使用授权书

本人完全了解武汉理工大学有关保留、使用学位论文的规定，即学校有权保留并向国家有关部门或机构送交论文的复印件和电子版，允许论文被查阅和借阅。本人授权武汉理工大学可以将本学位论文的全部内容编入有关数据库进行检索，可以采用影印、缩印或其他复制手段保存或汇编本学位论文。同时授权经武汉理工大学认可的国家有关机构或论文数据库使用或收录本学位论文，并向社会公众提供信息服务。

（保密的论文在解密后应遵守此规定）

研究生（签名）：李洁　导师（签名）：　　日期：2019.5.20

摘要

实体关系抽取作为信息抽取的主要任务之一，其目的在于确定无结构文本中两个实体的关系类别，为进一步构建知识图谱、智能问答等应用奠定了理论基础。目前实体关系抽取最常用的方法是有监督的关系抽取方法，尤其将深度学习框架的神经网络模型应用到实体关系抽取任务上，关系抽取的效果更加显著。虽然有监督的关系抽取方法准确率高，但该方法需要大量的人工标注语料，语料的标注过程耗时耗力，因此限制了大规模的实体关系抽取任务。针对人工标注语料严重缺乏的问题，远程监督方法能够通过知识库与语料库进行启发式对齐获取大量标注数据，成为了解决大规模关系抽取任务的主要途径。

然而，远程监督关系抽取方法容易产生大量噪声标注数据，影响实体关系抽取的性能。针对该问题，本文提出了一种基于语义相似度的降噪方法，同时结合注意力机制构建了一种融合多层次注意力机制的远程监督关系抽取模型，进一步提高远程监督关系抽取的效果。本文的主要研究工作如下：

（1）针对传统远程监督关系抽取方法容易产生大量噪声标注数据的问题，本文提出了一种基于语义相似度的噪声标注数据过滤方法。该方法通过基于词向量的 Jaccard 相似性度量方法计算句子中实体对之间最短依存路径与关系短语的语义相似度来判断句子是否被正确标注，语义相似度越高，句子正确标注的概率就越高，再将过滤后的标注数据输入到分段卷积神经网络（Piecewise Convolutional Neural Networks，PCNN）关系抽取模型中进行关系分类。最后通过实验验证，本文提出的降噪方法能够显著提高实体关系抽取的效果。

（2）针对目前远程监督关系抽取的研究未能充分利用句子上下文词语的高层语义，以及未考虑关系之间存在依赖包含问题，本文提出了一种融合多层次注意力机制的远程监督关系抽取模型。该模型分别在词语层、句子层以及关系层采用了注意力机制，词语层注意力能够充分获取句子上下文的高层语义信息，句子层注意力能够减少标签的错误标注问题，而关系层注意力则能够自动学习不同关系之间的依赖包含关系。在公共真实数据集上的实验结果表明，本文提出的模型相较于当前主流方法的准确率-召回率曲线提高了 4%左右，实现了更好的关系抽取效果。

关键词：实体关系抽取，远程监督，语义相似度，词向量，注意力机制

Abstract

As one of the main tasks of information extraction, entity relation extraction aims at determining the relation category of two entities in unstructured text, which provides the theoretical foundation for the construction of knowledge graph and intelligent question answering applications. At present, supervised methods are most commonly used for entity relation extraction. Especially, the effect becomes more significant when applying the neural network model of deep learning framework to entity relation extraction task. Although supervised relation extraction achieves high accuracy, it requires a large number of manually tagged corpus. The corpus tagging process is time-consuming, and thus affects the large-scaled extraction task. To address the shortage of manually tagged corpus, distant supervision method has become popular to solve the large-scaled relation extraction task, due to its ability of obtaining a large number of tagged data through heuristic alignment between knowledge base and corpus.

However, the distant supervision relation extraction method can easily generate a large number of noise data, which affects the performance of entity relation extraction. In order to solve this problem, this thesis proposes a denoising method based on semantic similarity, and constructs a distant supervision relation extraction model which integrates multi-level attention mechanism. The main research work of this thesis is as follows:

(1) Aiming at the problem of the large amount of noise data in traditional distant supervision relation extraction methods, this thesis proposes a noise data filtering method based on semantic similarity. This method determines whether a sentence is correctly labeled by calculating the semantic similarity between the shortest dependency path of entity pairs in the sentence and relational phrases, based on word embedding Jaccard similarity measurement. Then, the filtered tagged data are classified by Piecewise Convolutional Neural Networks (PCNN) relation extraction model. Finally, the experimental results show that the proposed denoising method can significantly improve the effect of entity relation extraction.

(2) The high level semantics of the context words in a sentence are usually not fully utilized, and the dependency-inclusion between relations is not considered in the

current research of distant supervision relation extraction. This thesis proposes a distant supervision relation extraction model integrating multi-level attention mechanism. In this model, attention mechanism is applied at word-level, sentence-level and relation-level. Word-level attention can fully obtain the high-level semantic information of sentence context. Sentence-level attention can reduce the error in labeling, and the relation-level attention can automatically capture the dependency-inclusion between different relation. The experimental results on public real data sets show that the proposed model can improve the Precision-Recall curve by about 4% compared with the existing mainstream methods, and achieve better effect of relation extraction.

Keywords: entity relation extraction, distant supervision, semantic similarity, word embedding, attention mechanism

目 录

摘要 I

Abstract II

第 1 章 绪论 1

1.1 研究背景及意义 1

1.1.1 研究背景 1

1.1.2 研究意义 2

1.2 国内外研究现状 2

1.2.1 有监督的关系抽取方法 3

1.2.2 半监督的关系抽取方法 5

1.2.3 无监督的关系抽取方法 6

1.2.4 远程监督的关系抽取方法 6

1.3 研究内容与技术路线 7

1.4 论文结构安排 9

第 2 章 远程监督关系抽取方法分析 10

2.1 远程监督关系抽取原理 10

2.2 远程监督关系抽取流程 11

2.2.1 启发式对齐 12

2.2.2 特征提取 13

2.2.3 训练分类器 15

2.2.4 关系抽取 15

2.3 远程监督的噪声标注问题及降噪方法 16

2.3.1 噪声标注问题 16

2.3.2 相关降噪方法 17

2.4 本章小结 19

第 3 章 基于语义相似度的远程监督噪声标注过滤方法 20

3.1 基于语义相似度的噪声标注过滤框架 20

3.2 最短依存路径的获取 21

3.2.1 依存句法分析 21
3.2.2 最短依存路径 22
3.3 基于词向量的 Jaccard 相似度计算方法 23
3.3.1 传统 Jaccard 相似度计算方法 23
3.3.2 基于词向量的 Jaccard 语义相似度计算方法 24
3.4 基于分段卷积神经网络的关系抽取模型 25
3.5 实验准备 27
3.5.1 语料库和知识库 27
3.5.2 实验设置 28
3.6 实验设计与结果分析 29
3.6.1 不同相似度计算方法对比 29
3.6.2 最优相似度阈值 δ 确定 30
3.6.3 噪声数据过滤效果对比 32
3.7 本章小结 33
第 4 章 基于多层次注意力机制的远程监督关系抽取模型 34
4.1 基于注意力机制的关系抽取方法 34
4.1.1 注意力机制相关理论 34
4.1.2 关系抽取任务引入注意力机制 36
4.2 融合多层次注意力的远程监督关系抽取模型 37
4.2.1 模型整体设计 37
4.2.2 基于 BGRU 神经网络的句子向量表示 38
4.2.3 引入实体上下文的词语层注意力 40
4.2.4 引入实例置信度的句子层注意力 41
4.2.5 引入依存关系的关系层注意力 42
4.2.6 模型训练与优化 42
4.3 实验准备 43
4.3.1 数据集与评估标准 43
4.3.2 实验环境与参数设置 43
4.4 实验设计及结果分析 44
4.4.1 当前主流方法对比 44
4.4.2 不同注意力机制对模型的影响 45
4.4.3 不同句子数量对模型的影响 47

4.5 本章小结 48
第 5 章 总结与展望 49
5.1 总结 49
5.2 工作期望 50
致谢 51
参考文献 52
攻读学位期间获得与学位论文相关的科研成果 56

第 1 章 绪论

1.1 研究背景及意义

1.1.1 研究背景

随着信息化技术的快速发展，人们获取知识的方式发生了极大的改变，逐渐从书籍、报纸等传统渠道转变为从互联网上主动获取知识的学习模式。互联网作为一个信息共享的平台，其信息爆炸式的增长速度已经远远超过人类理解的速度，给人们从海量的数据中快速且精确地获取自己所需要的信息带来了巨大的困难。搜索引擎作为目前最普遍的信息处理工具，它能够根据特定策略搜集和组织互联网上数以亿计的网页文档，并对每个网页的关键词建立索引，形成规模庞大的索引库，最后通过关键词匹配的方式对网页进行索引检索和排序，获取用户可能需要的信息。基于关键词相似度匹配和网页质量排序的分析引擎虽然在一定程度上可以获取到用户所关注的信息，但是无法真正理解用户的查询语义以及网页中所包含的语义信息，导致大部分的网页信息并不是用户真正需要的，更不能以简洁直观的方式显示给用户。同时，网页中包含了大量的无用内容可能会干扰用户有效地获取所需信息。因此，迫切需要一种能够深层次地进行文本分析的技术解决这一问题。信息抽取技术主要是在从无结构化或半结构化文本中（如网页、新闻、日志文件等）自动抽取出大量的结构化信息并将其进行归类整理，然后统一存储在数据库中，方便用户通过检索获取自己所需要的信息。信息抽取不仅是人工智能领域的核心技术之一，而且为自动文摘、机器翻译等其他应用提供了理论基础。

实体关系抽取作为信息抽取的主要任务之一，旨在已经识别出实体的句子中发现并提取出实体之间的语义关系。随着大数据时代的迅速发展，由此产生的关系类型越来越复杂，如人类之间的社交关系、事物之间的属性关系等，而这些自然文本中所蕴含的关系大多属于潜在关系，不容易被直接提取，从而使得从无结构文本中提取出实体之间的语义关系变得更加困难和不可预测。因此，如何更加精确而有效地抽取出实体间的关系，为其他自然语言处理应用提供技术支持，逐渐成为当前信息抽取领域的研究重点。

1.1.2 研究意义

实体关系抽取的主要任务是从无结构的自由文本中提取出实体间二元关系，并以三元组<实体 e1，实体 e2，关系 r>的形式进行表示[1]。例如，给定一个句子："<e1>Trump</e1> was born in the <e2> New York </e2> just as he has always said."，通过关系抽取将自动识别这个句子的关系：<Trump，New York，Born In>，表示"Trump"和"New York"的关系是"Born In"。通过提取出实体间的语义关系，可以更好地建立实体之间的语义链接，帮助计算机更好地处理大规模的网络文本数据，从而理解非结构化文本的语义信息。

实体关系抽取在知识库的自动构建、智能问答以及信息检索等领域有着广泛的理论价值和实践意义。首先，关系抽取可以为知识库的自动构建提供技术支持，传统知识库主要依靠人工归纳构建，耗时耗力，而且只限于专家领域知识库，覆盖面较小。通过关系抽取算法识别实体之间的关系可以实现开放领域的知识库的自动更新和扩充，丰富和完善了知识库，如 FreeBase、DBpedia 和知立方都是通过自动构建形成的成熟知识库。其次，关系抽取能够为智能问答系统应用提供数据支持，通过关系抽取获得的关系三元组存储在数据库中，当有用户提问时，智能问答系统能够从其结构化数据库中快速准确地检索到相应的答案反馈给用户。同时，关系抽取能够对信息检索服务进行优化，目前的信息检索主要基于关键词相似度匹配，难以做到知识的推理和预测，通过关系抽取获得的结构化数据能够设计基于逻辑和图的知识推理算法，进一步挖掘隐藏信息，更加精确地获取用户的检索目标。

1.2 国内外研究现状

实体关系抽取任务首次提出是在 1998 年的消息理解会议（Message Understanding Conference，MUC）评测任务上，MUC 提出了关于特定模板关系的抽取任务。随后，自动内容提取会议（Automatic Content Extraction，ACE）和语义评测会议（Semantic Evaluation，SemEval），也将实体关系抽取纳入其中一项重要的评测任务，吸引了大量的相关领域学者参与关系抽取任务的测评。在这些评测会议的推动下，实体关系抽取得到了长足的发展。目前，大多数评测会议的学者和研究人员将关系抽取任务主要转化为关系分类问题进行研究，根据关系抽取方法对标记语料依赖程度的不同，可以将其归纳为有监督、半监督、无监

督以及远程监督四类方法[2]。下面将对这四种方法的国内外相关研究现状进行阐述。

1.2.1 有监督的关系抽取方法

有监督的关系抽取方法是当前使用最普遍且准确率最高的方法，其主要思想：在人工标注数据集上通过语义和句法分析构建有效的特征集合，训练出合适的关系模型，然后使用该训练模型在测试集上进行关系类型的识别和分类。目前有监督的关系抽取方法可分为基于规则、基于特征工程、基于核函数和基于深度学习四种方法。

基于规则的方法是最早出现的关系抽取方法，该方法主要通过领域专家人工总结出实体关系的语法模板并归纳出对应的关系语义模式，然后采用模式映射的方式实现关系的提取。在实体关系抽取早期研究，不少学者[3-4]采用基于规则模板的方法实现较好的关系抽取效果，但是该方法由于规则模板的制定过于严谨，且过度依赖于语言学知识和人工归纳，导致该方法的召回率很低，领域移植性差，无法得到广泛应用。

基于特征工程的方法主要是从句子实例中启发式地提取出句法和语法信息作为特征集合，根据句子的特征构造特征向量，然后利用特征向量构建出关系抽取模型，从而实现关系抽取任务。Kambhatla 等人[5]选取实体类型和句子上下文等特征构造特征向量，然后采用最大熵分类器实现英文语料中实体关系抽取任务；Tratz 等人[6]在 Kambhatla 研究的基础上对句子的上下文特征进行扩展，并采用布尔值对特征向量进行表示，最终在 SemEval 2010 数据集中取得了优异关系抽取效果；甘丽新等人[7]针对中文句式复杂和数据稀疏的问题，将依存句法组合特征和最近句法依赖动词特征加入到特征向量中，并使用支持向量机进行关系抽取，最后在中文旅游数据集上验证了新增关系特征的可行性。

由于复杂的语法结构和繁重的特征选取工作，使得特征工程的方法性能无法继续提升。基于核函数的方法不需要构造离散的高维特征向量，而利用核函数计算句子解析树之间的相似性进行关系抽取。Zelenko 等人[8]首次在关系抽取任务中使用到核函数概念，提出了一种定义在文本浅解析表示层的核函数，并将该核函数与支持向量机算法和 Voted Perceptron 算法相结合，用于从文本中抽取出隶属关系和组织位置关系。Culotta 等人[9]在 Zelenko 的研究基础上进行了扩展，通过生成与句子上下文相关的依赖树来增强表示核函数，实验证明基于依赖树

核函数的方法比基于词袋模型核函数的方法在准确率上提高了 20%左右。除了上述提到的核函数之外，还有最短依存路径核[10]、语义序列核[11]和卷积树核[12]等常见的核函数。基于核函数的方法能够利用句子语法结构信息，避免构造高维特征向量，但是核函数运算过程繁琐，当数据规模过大时，模型的训练和测试速率缓慢，导致该方法整体性能低下。

以上三种关系抽取方法大都是基于传统的统计机器学习方法，严重依赖于词性标注、语法分析等自然语言处理工具，而这些工具在进行句子解析时会出现一定的错误，降低了实体关系的抽取效果。同时，无论是规则模板的归纳，还是特征的提取，上述方法都严重依赖于语言学知识和人工经验，耗费大量的人力财力。随着深度学习技术在自然语言处理领域的深入研究，该技术也被广泛应用到实体关系抽取任务上。基于深度学习的方法能够自动学习和提取句子语法特征，从而避免了特征提取和自然语言处理工具带来的错误传播等问题，关系抽取的性能和效果也有了很大的提高。

卷积神经网络（Convolutional Nenual Network，CNN）由于能够捕捉句子的局部关键特征，在多个自然语言处理任务（文本分类[14]、自动文摘[15]、情感分析[16]等）上都有不错的表现。Liu 等人[17]可能是最早在关系抽取任务中提出了使用 CNN 模型自动提取句子特征，并引入同义词词典对输入词进行编码，将语义信息集成到神经网络中，实验证明该方法的抽取效果比当时最优的基于多核融合的核函数方法提高了 9%。Nguyen 等人[18]在关系抽取模型中采用多尺寸过滤器 CNN 模型，将预先训练好的词向量和实体相对位置向量作为模型输入，最小化外部工具包和资源的依赖。王林玉等人[19]在结合词向量和位置向量作为输入的经典 CNN 模型上，并融合了类别关键词策略，提出了基于句子层的多类别关键词特征抽取算法，减少关键特征丢失，提高了关系抽取效果。由于 CNN 模型无法解决句子实体长距离依赖的问题，不少研究者将循环神经网络（Recurrent Neural Network，RNN）应用到关系抽取任务中。Luo 等人[20]提出了一种基于远距离关系模式的 RNN 模型用于临床记录的关系抽取，相较于 CNN 模型，RNN 模型能够充分利用句子上下文信息，更适合长句子的关系抽取任务。Sundermeyer 等人[21]对 RNN 模型改进，提出了长短时记忆网络（Long Short Term Memory Network，LSTM）模型，解决传统 RNN 模型存在的梯度消失和梯度爆炸问题。Banerjee 等人[22]提出了一种新型的多编码器 LSTM 模型来识别给定句子中的关系类别，在每个编码器中使用不同的语法特征，然后将所有编码器的隐含状态进行互连来预测关系类型，实验证明多编码器的 LSTM 模型能够有效提高关系抽

取效果。王红等人[23]针对长句子远距离依赖和输入输出无关联的问题，提出了一种将双向 LSTM 模型和注意力机制相结合的实体关系抽取模型。

有监督的关系抽取方法虽然有着较高的准确率和较好的整体性能，但其训练过程需要大量标注语料，而关系语料的标注过程依靠人工进行，耗时耗力，目前大多研究者使用的关系数据集都是已经标注好的权威语料库，或者自己标注的语料。标注语料的严重缺乏，导致有监督的关系抽取方法不适合大规模的关系抽取任务。

1.2.2 半监督的关系抽取方法

为了减少构建语料库繁重的人工标注过程，实现大规模环境下实体关系的自动识别和提取，半监督学习的关系抽取方法应运而生。该方法只需要少量标注的种子数据集进行训练学习，得到一个指导性的关系分类模型，重复性地从未标注语料抽取出置信度较高的关系实例加入到种子关系集中，在迭代过程中不断扩充种子集合，从而达到实体关系抽取的效果。

Brin[24]最早提出了基于 Bootsrapping 自扩展技术的半监督关系抽取方法，用于抽取 Web 网页中书籍-作者（book-author）的属性关系。该方法首先手工定义少量的 book-author 关系实例作为种子集，并从种子集合总结归纳出关系序列模式，然后将语料文本与关系序列模式进行匹配发掘出新的关系种子集，通过不断的迭代学习，直到未标注语料的实体关系均被抽取。由于上述方法没有对关系序列模式进行评估，无法保证关系模式的可靠性，Agichtein 等人[25]在 Brin 的研究基础上进行改进，提出了 Snowball 半监督关系抽取模型，该模型在迭代过程中采用可扩展的度量标准对关系模式进行置信度评估，选取置信度较高的关系模式作为下一轮迭代的种子模式，从而降低了噪声模式带来的语义漂移问题。鉴于 Snowball 模型具有稳定的关系抽取性能，Liu 等人[26]在其基础上进行扩展，提出了多类型关系模式的 MutilSnowball 关系抽取模型，用来解决多种关系类型模式不能共存的问题。何婷婷等人[27]则将种子自扩展的半监督方法用于中文实体关系抽取，并在《人民日报》语料库取得了 81.3%的抽取效果。由于基于 Bootstrapping 的半监督关系抽取方法容易在迭代过程出现“语义漂移”现象，Cvitas 等人[28]研究了基于协同学习（co-learning）思想的半监督关系抽取方法，通过结合两个相互独立的特征集进行协同学习，获取互补的关系特征信息，从而降低噪声标注的现象。

半监督关系抽取方法在一定程度上能够有效地降低人工参与程度，在信息抽取方面具有极大的潜力。但是，在自动迭代过程中可能会产生大量噪声数据引起语义漂移的情况，导致该方法的召回率较低。因此，如何选取高质量的种子关系集以及如何训练置信度高的关系模式进行降噪处理，是当前半监督关系抽取方法的研究重点。

1.2.3 无监督的关系抽取方法

相较于上述两种方法，无监督关系抽取方法最大特点就是不需要预先对句子的关系类型进行定义，而是采用聚类的思想，将语义相似的句子进行聚合，然后选择能够表达语义关系的关键词来标记句子集合的关系标签。

Hasegawa 等人[29]最早提出了一种基于实体对上下文聚类的无监督关系抽取方法，该方法将相同实体对之间的上下文信息作为语义特征，采用全联通聚类方法对这些特征进行聚合，然后从每一个聚类中选择出现频率最高的关键词作为该类的关系标签，由此奠定了无监督关系抽取方法的基础。针对 Hasegawa 的方法无法提取实体对之间的隐含语义关系，Zhang 等人[30]通过生成句法结构树作为实体句子的特征，采用核函数计算关系实例的相似性，并使用平均聚类算法实现了低频实体对之间的语义关系提取。Quan 等人[31]在生物医学文献的实体关系抽取研究中，采用基于模式聚类的无监督学习方法进行蛋白质交互关系抽取。该方法从未标记的数据中识别关系交互词，并将这些交互词与句子依赖分析和短语结构分析相结合进行实体对间的关系提取。在中文实体关系抽取方面，孙勇亮[32]则将密度聚类算法应用到开放领域的中文实体关系抽取任务中，同时结合特征选择排序算法提高关系识别的准确率。

总而言之，基于无监督学习的关系抽取方法不需要人工标注语料，具有领域无关性、可移植性强的特点，在大规模的关系抽取任务中与其他方法相比有着极大的优势。但是无监督关系抽取方法在选择聚类方法时，缺乏客观的理论依据，且聚类阈值难以确定，导致该方法的准确率和召回率较低，关系抽取效果欠佳。

1.2.4 远程监督的关系抽取方法

远程监督关系抽取方法不需要大量的标注数据就能实现实体关系抽取任务，因此受到了不少学者的青睐。该方法是由 Mintz 等人[33]提出用来解决人工标注语料缺乏的问题，主要是利用现有知识库中包含的关系实例，将其与语料库中的

文本进行实体映射，从而获取大量带有标注的语料。由于远程监督方法容易产生大量的噪声标注数据，不少研究将如何减少噪声标注作为远程监督方法的研究重点。Riedel 等人[34]对此阐述了一种更加松弛的 at-least-one 确定性假设，并在此假设的基础上提出了基于无向图的远程监督关系抽取模型，获取大量的关系三元组。Hoffmann 等人[35]和 Surdeanu 等人[36]分别提出了多实例学习和多实例多标签的方法来缓解错误标注问题。Benjamin 等人[37]则将主题模型 LDA 和判决学习方法相结合，用来减少远程监督结果中的噪声数据。

由于深度学习技术在自然语言处理领域的出色表现，不少研究也开始将神经网络模型和注意力机制应用到远程监督关系抽取任务中，Zeng 等人[38]采用分段最大池的卷积网络自动学习句子特征，并结合多实例学习进行远程监督关系抽取；而 Lin 等人[39]在 Zeng 的远程监督关系抽取模型中引入了句子层注意力机制，充分利用语料中所有包含两个实体对的句子，通过赋予关系标注正确实例更高的权重，减少噪声标注。Ji 等人[40]在考虑句子层的注意力机制的同时，从知识库中引入已标注实体的描述信息，加强对实体的向量表示学习，从而提高关系抽取准确率。Lei 等人[41]为了有效地模拟文本语料库与知识图谱信息之间的语义模式，构建出一种具有双向知识蒸馏的神经网络关系抽取模型，可以协同使用不同的信息源，得到了更好的关系抽取效果和性能。Feng[42]等人利用强化学习框架提出了一种由实例选择器和关系分类器组成的远程监督关系抽取模型，实例选择器选取高质量的句子实例馈送到关系分类器中，关系分类器则将预测结果反馈给实例选择器，两个模块联合优化，有效降低了远程监督存在的噪声标签问题。

1.3 研究内容与技术路线

由于目前实体关系抽取任务中人工标注语料严重匮乏，本文将结合知识库和语料库采用远程监督的方法进行实体关系的抽取。然而，传统远程监督关系抽取方法还面临着以下两个挑战：

（1）在传统远程监督关系抽取中，由于远程监督的语义假设过于严格，造成了大量的噪声标注问题，从而影响了标注训练集的质量。如何有效地减少远程监督过程中产生的噪声标注数据是远程监督关系抽取方法亟须解决的任务。

（2）深度学习技术能够在实体关系抽取任务中自动学习句子特征，无需复杂的特征工程，避免了传统自然语言处理方法造成的错误传播问题。如何结合深度学习技术生成一体化程度较高的远程监督关系抽取模型，进一步提高实体关

系的抽取效果仍有待研究。

因此，本文将从如何有效地过滤远程监督关系抽取方法中产生的噪声标注数据，以及结合深度学习技术构建远程监督关系抽取模型两个方面进行研究：

（1）基于语义相似度的噪声标注数据过滤方法

针对传统远程监督关系抽取方法容易产生大量错误标注数据的问题，本文提出了一种基于语义相似度的噪声标注数据过滤方法，该方法首先通过依存句法分析获取原始标注数据的最短依存路径；然后采用基于词向量的 Jaccard 相似性度量方法计算句子的最短依存路径与关系短语之间的语义相似度来判断句子是否被正确标注，语义相似度越高，句子正确标注的概率就越高；最后将过滤后的标注数据通过分段卷积神经网络关系抽取模型进行关系分类。

（2）融合多层次注意力机制的远程监督关系抽取模型

针对目前远程监督关系抽取的研究未能充分利用句子上下文词语的高层语义，以及未考虑关系之间的依赖包含问题，本文提出了一种融合多层次注意力机制的远程监督关系抽取模型。该模型首先通过双向门控循环单元神经网络对句子词向量进行编码来获取句子高维语义；其次通过引入词语层注意力来计算两个实体与上下文词语的相关程度，从而充分捕捉句子中实体上下文的语义信息；然后在多个实例上构建句子层的注意力来减少标签错误标注的问题；最后通过关系层的注意力自动学习不同关系之间的依赖包含关系。

本文的主要工作路线图如图 1-1 所示：

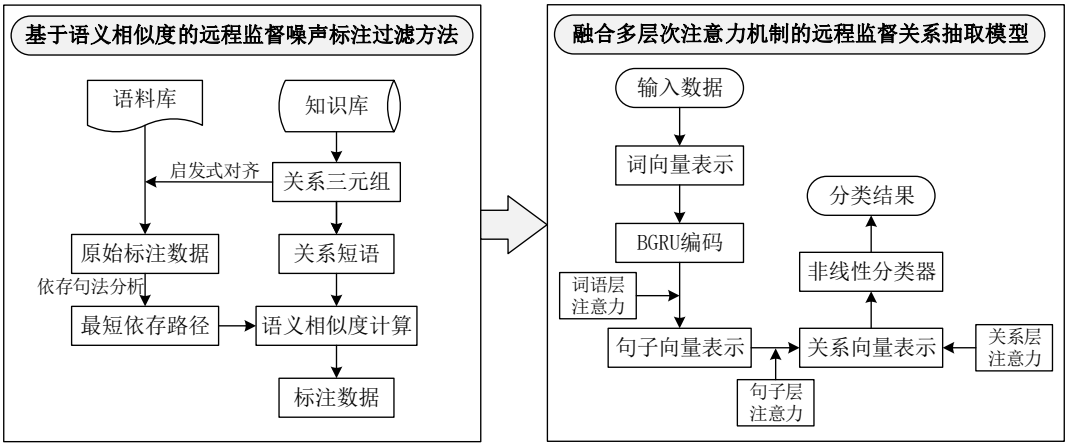

图 1-1 主要的技术路线图

1.4 论文结构安排

根据以上的研究内容，本文共分为五个章节进行论述，章节内容如下：

第 1 章 绪论。首先对本课题的研究背景和意义进行了论述，然后分别详细阐述了基于有监督、半监督、无监督和远程监督四种不同实体关系抽取方法的国内外研究现状，最后归纳出研究内容和技术路线，以及论文的结构安排。

第 2 章 远程监督关系抽取方法分析。首先对远程监督关系抽取的原理进行了归纳整理，然后介绍了远程监督关系抽取的主要流程，并对每一步的流程进行了简要阐述，然后结合实例具体分析了传统远程监督关系抽取存在的噪声标注问题以及相关的降噪方法。

第 3 章 基于语义相似度的远程监督噪声标注过滤方法。本章主要提出了基于语义相似度的噪声标注数据过滤框架。首先对依存句法和最短依存路径的相关理论进行阐述，然后在传统 Jaccard 算法基础上提出了基于词向量的 Jaccard 相似性度量方法，用来计算最短依存路径上的短语与关系短语的语义相似度，并依据该相似度判断标注数据是否正确标注，最后将过滤后的标注数据输入分段卷积神经网络关系抽取模型进行关系分类。实验结果验证了该方法对于过滤远程监督噪声标注数据是有效的。

第 4 章 基于多层次注意力机制的远程监督关系抽取模型。首先简要描述了注意力机制的相关理论，并以 PCNN+ATT 模型为例阐述了引入注意力机制对提高远程监督关系抽取效果的影响；然后提出了融合多层次注意力机制的远程监督关系抽取，分别在词语层、句子层以及关系层采用了注意力机制，最后在公共数据集上的实验结果表明，本文提出的方法相较于当前主流方法有了较大的进步。

第 5 章 总结与展望。对本文的研究工作进行全面总结，指出研究过程中存在的不足，并对未来的研究重点和改进方向作出展望。

第 2 章 远程监督关系抽取方法分析

由于目前实体关系抽取任务中人工标注语料严重缺乏，本文采用远程监督的方法进行实体关系抽取。本章将对基于远程监督的实体关系抽取框架进行分析，主要介绍远程监督关系抽取方法的原理和流程，并结合具体实例分析远程监督关系抽取存在的噪声标注问题以及相关的降噪方法。

2.1 远程监督关系抽取原理

目前关系抽取任务中最常用的基本方法是有监督的关系抽取方法，尤其将深度学习框架的神经网络模型应用到实体关系抽取任务上，关系抽取的效果更加显著。虽然该方法的准确率很高，但是严重依赖人工标注语料，特别是基于神经网络的深度学习方法，模型参数众多且结构复杂，为了避免模型过拟合，需要更多的标注语料进行训练。然而，语料的标注过程主要依靠人工根据语言学知识进行归纳，耗时耗力，代价昂贵，导致基于有监督学习的方法难以适应大规模自由文本的关系抽取任务。

为了缓解当前标注语料严重缺乏的现状，Mintz 等人[33]采用远程监督的方法进行实体关系抽取研究，该方法最大的优点是不需要人工标注语料，而是利用结构化知识库与原始非结构化的自由文本进行启发式对齐，使用知识库中的实体三元组启发式地训练一个实体关系分类器来扩充关系实例，从而获取大规模关系三元组。表 2-1 给出了远程监督关系抽取任务中的相关概念。

表 2-1 相关概念

名称	含义
语料库	用于存储半结构化或非结构化数据的自由文本集合，常用的语料库有维基百科、New York Times、人民日报等
知识库	用于收集、存储和共享人类世界客观知识的数据集合，常用的知识库有 FreeBase、YAGO、Dbpedia 等
实体	表示客观存在的对象，如人名、地名、组织名等
关系	表示客观对象之间存在的联系，在知识库中表示实体对的关联
关系三元组	构成知识库的基本元素，用来表示客观存在的知识，通常表示形式为<实体 1，关系，实体 2>

远程监督关系抽取方法的核心思想来源于一个严格的假设：若一对实体包含某种特定关系，则所有包含这对实体的语句都属于这种关系，并且这些语句可以作为该关系标签的训练正例。具体来讲，在使用远程监督方法构建训练实例集时，是将知识库 K 中的关系三元组通过实体启发式对齐的方式映射到语料库 D，从而构建标注句子实例集 S：

$$S = \{\ s_m \mid s_m = (e_i, r_k, e_j),\ s_m \in D\ \} \qquad (2\text{-}1)$$

其中，e_i和e_j分别为语料库 D 中的目标实体，r_k为e_i和e_j在知识库 K 中的语义关系，s_m为 D 中包含e_i和e_j的句子。如果 D 中存在句子s_m，同时包含实体e_i和e_j，且 K 中存在关系三元组(e_i, r_k, e_j)，则句子实例s_m可以判定为关系r_k的正例。通过此方法可以构造大量带有关系标签的句子实例集合，然后利用这些句子实例训练出关系抽取模型，从而在测试语料中进行实体关系的识别。

2.2 远程监督关系抽取流程

根据远程监督的语义假设不难发现，远程监督关系抽取方法并不是一个简单的模式匹配的过程，还需要一定的特征提取和分类工作。图 2-1 展示了远程监督关系抽取流程：

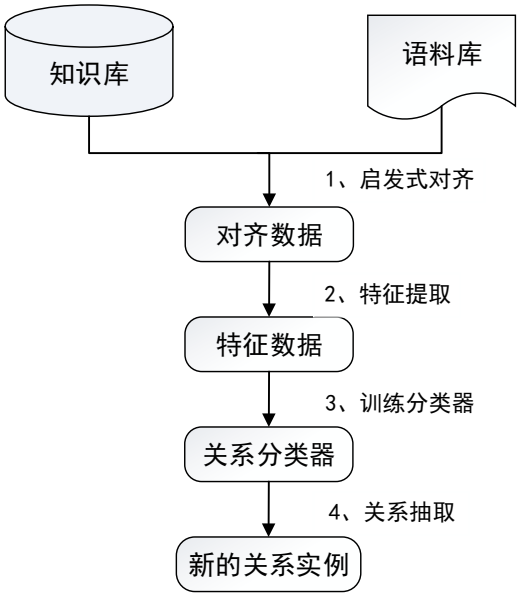

图 2-1 远程监督关系抽取流程图

远程监督关系抽取流程包括以下四个关键步骤：①语料库与知识库进行启发式对齐获得原始对齐数据；②对齐数据的特征提取；③使用特征数据训练关系分类器；④利用关系分类器抽取新的关系实例；下面将对远程监督关系抽取的主要流程进行详细阐述。

2.2.1 启发式对齐

为了获取大量的标注数据，首先需要将语料库文本与知识库中的关系实例进行启发式对齐。启发式对齐是远程监督关系抽取方法中的核心流程，主要基于远程监督的原始假设：若一对实体包含某种特定关系，则所有包含这对实体的语句都属于这种关系。换言之，如果两个目标实体存在于知识库的某个关系实例中，就将语料库中所有包含两个目标实体的语句通过实体匹配的方式筛选出来，而这些语句都属于实体对在关系中的语义关系。例如，在 FreeBase 知识库中存在已知关系三元组<Thailand，Bangkok，/location/country/capital>，通过启发式对齐维基百科文本中的实体，可以得到多个包含 Thailand 和 Bangkok 实体对的句子实例，启发式对齐过程如图 2-2 所示，根据启发式对齐的假设条件可知，这些句子都表达了/location/country/capital 的关系。

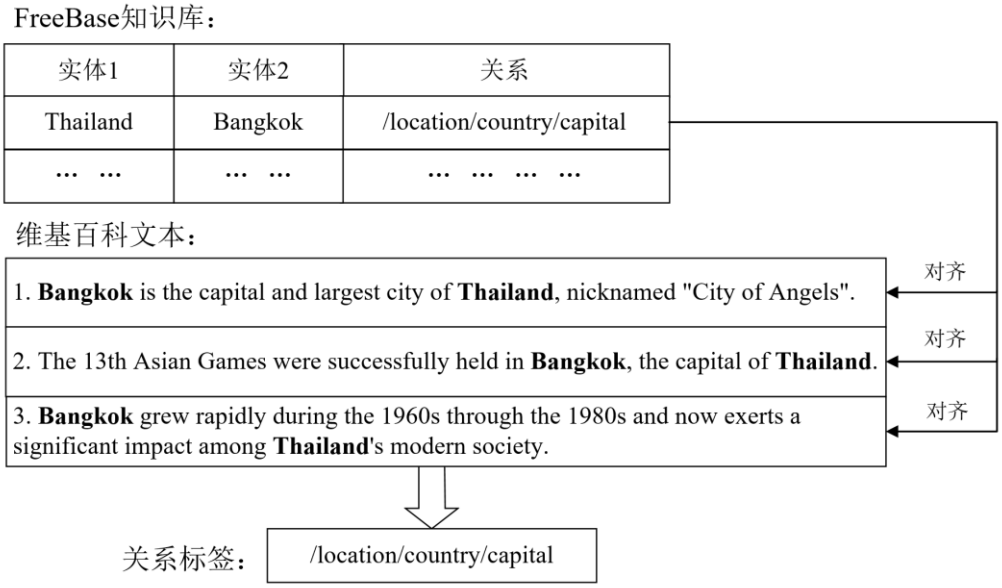

图 2-2 FreeBase 知识库与维基百科语料库的启发式对齐过程

关系三元组<Thailand，Bangkok，/location/country/capital>和得到的句子实例共同构成了一个启发式对齐数据，其中启发式对齐算法如表 2-2 所示：

表 2-2 启发式对齐算法实现

Algorithm：启发式对齐

Input：（1）知识库 KB （2）语料库 TEXT

Output：对齐数据集合

```
relation_data = defaultdict(list)
for each doc in TEXT;
    for each sentence in doc;
        pairs = get_entity_pairs(sentence)
        for each(e1, e2) in pairs;
            relation = get_relation(e1, e2, KB)
            if is_exist(relation);
                relation_data[(relation, e1, e2)] append(sentence)
            end if
        end for
    end for
end for
```

2.2.2 特征提取

在远程监督关系抽取方法中，特征提取的过程是将能够表达原始自由文本中的关键语义的特征信息筛选出来，并将其使用相关自然语言处理工具进行特征量化，使得这些特征信息能够被计算机处理。文本的语义特征信息能够潜在地表达出句子实体对之间存在的语义关系，因此，在构建关系抽取模型时需要选取那些能够充分表达文本含义的关键特征信息。在实体关系抽取任务中，常用的文本特征信息包括词汇特征和语义特征，这两种特征都从不同方面反映了两个实体是怎样表现它们之间的关系。

（1）词汇特征

词汇特征通常表示句子中单词所包含信息特征，主要是指单词所包含词性特征和实体类型特征。

词性特征主要描述了词语的词性信息，如动词、名词、形容词、介词等，每一种词性在句子中都具有不同的意义。在自然语言处理领域中，一般都根据词性的不同对语料中的词语进行分类，并赋予不同词性类型对应的类别标签，该过程

被称为词性标注（Parts-of-Tagging，PoS Tagging），不同的词性标注任务有着不同的词性标注集合。图 2-3 是一个 NLTK 所使用的全部词性标注集，该集合采用不同的标记符合来表示不同的词性。

标记	全称	含义	标记	全称	含义
CC	Coordinating conjunction	连接词	PRP$	Possessive pronoun	所有格代名词
CD	Cardinal number	基数词	RB	Adverb	副词
DT	Determiner	限定词	RBR	Adverb, comparative	副词比较级
EX	Existential there	存在句	RBS	Adverb, superlative	副词最高级
FW	Foreign word	外来词	RP	Particle	小品词
IN	Preposition or subordinating conjunction	介词或从属连词	SYM	Symbol	符号
JJ	Adjective	形容词或序数词	TO	to	介词或不定式格式
JJR	Adjective, comparative	形容词比较级	UH	Interjection	感叹词
JJS	Adjective, superlative	形容词最高级	VB	Verb, base form	动词基本形式
LS	List item marker	列表标示	VBD	Verb, past tense	动词过去式
MD	Modal	情态助动词	VBG	Verb, gerund or present participle	动名词和现在分词
NN	Noun, singular or mass	常用名词单数	VBN	Verb, past participle	过去分词
NNS	Noun, plural	常用名词 复数	VBP	Verb, non-3rd person singular present	动词非第三人称单数
NNP	Proper noun, singular	专有名词单数	VBZ	Verb, 3rd person singular present	动词第三人称单数
NNPS	Proper noun, plural	专有名词复数	WDT	Wh-determiner	限定词
PDT	Predeterminer	前位限定词	WP	Wh-pronoun	代词
POS	Possessive ending	所有格结束词	WP$	Possessive wh-pronoun	所有格代词
PRP	Personal pronoun	所有格代名词	WRB	Wh-adverb	疑问代词

图 2-3 NLTK 词性标注集

NLTK 是一个基于 Python 构建的用于处理自然语言数据的工具包，可以高效地对语料中的句子进行词性标注。例如，输入句子“Jerry's big idea isn't all that bad.”，词性标注结果输出为“[('John', 'NNP'), ("'s", 'POS'), ('big', 'JJ'), ('idea', 'NN'), ('is','VBZ'), ("n't", 'RB'), ('all', 'DT'), ('that', 'DT'), ('bad', 'JJ'), ('.', '.')]”。

实体类型特征又称命名实体识别，可以用来识别出句子中的实体成分，为进一步实现实体关系抽取奠定基础。目前具有代表性命名实体识别方法主要是基于概率统计的机器学习方法，该方法一般是利用已经标注好或部分标注的实体数据进行训练，然后利用全自动或半自动的方法实现命名实体的识别与分类。常见的命名实体识别工具有 Stanford NER 工具包，该工具包按照实体类型提供了三种不同的命名实体识别方式，如表 2-3 所示：

表 2-3 Stanford NER 命名实体识别的三种方式

3 类	Location，Person，Organization
4 类	Location，Person，Organization，Miscellaneous
7 类	Location，Person，Organization，Time，Money，Percent，Date

（2）语义特征

语义特征就是根据语料中实体以及实体之间的单词序列所表达的含义进行特征建模。通常在选择语义特征时，除了要关注实体本身，还是考虑实体前后K个词汇的特征信息。一般采用以下几种语义特征进行特征建模：

① 实体之间的单词序列；

② 实体之间每个词汇的词性；

③ 实体的顺序标记值；

④ 实体1左侧K个词语及其词性；

⑤ 实体2右侧K个词语及其词性；

因此，每一个输入句子的语义特征都是通过上述五种特征信息进行描述的综合体，其中K的取值为{0,1,2}，这样就可以将实体之间的上下文的语义信息归入句子的语义特征中。

2.2.3 训练分类器

通过语料库与与知识库启发式对齐、句子特征提取两个步骤后，还需要将原始标注语句中的特征信息进行量化，通过处理工具映射为高维的特征向量，然后将量化后特征数据输入到关系分类器中，对分类器不断进行训练，直到分类器达到稳定状态。在原始远程监督关系抽取方法中， Mintz 等人采用的是多级逻辑分类器，并使用具有高斯正则化的L-BFGS进行了扩展。分类器的输入数据是通过实体对匹配的方式在语料文本中筛选出的所有包含知识中目标实体对的语句，这些语句都会当作相应关系标签的训练数据。例如，关系三元组<Thailand，Bangkok，/location/country/capital>进行启发式对齐时，如果在维基百科语料库中找到200个包含实体Thailand和实体Bangkok的句子，那么这些句子都会被用来对关系标签/location/country/capital进行训练。

2.2.4 关系抽取

当完成关系分类器的训练后，需要使用训练好的分类器去抽取新的关系实例。分类器的输入数据为实体对和包含该实体对语句的特征向量，输出结果为两个实体预测的关系类型和该关系类型的概率大小。如果测试数据中的实体对属于多个关系标签，那么将实体对所属的各个关系类型按照概率大小进行排序，然后

选取前 n 个概率最高的关系实例作为输出结果。

2.3 远程监督的噪声标注问题及降噪方法

2.3.1 噪声标注问题

远程监督方法在进行实体关系抽取时，能够将知识库和语料库紧密联系起来，高效地利用知识库中关系实例学习到一种新型的关系抽取模型，是当前解决大规模实体关系抽取的主要途径。虽然该方法在一定程度上能够完成语料集的自动标注，减少人工标注语料的依赖，但是由于提出的假设过于严格，很容易出现错误标注的现象。以图 2-4 中知识库中的关系三元组和已知标注数据为例：

知识库	Born in(**Donald Trump**, **United States**) President of(**Donald Trump**, **United States**)

	文本句子	关系标签
正确标注数据	1. **Donald Trump** is the 45th and current President of the **United States**.	President of
	2. **Donald Trump** was born in the **United States** just as he has always said.	Born in
	3. **United States** President **Donald Trump** meet with German Chancellor Angela Merkel today.	President of
	4.**Donald Trump** announced that he would participate in the presidential election of the **United States**.	NA

图 2-4 关系三元组和已知标注数据

从图 2-4 可以看出，如果使用远程监督的方法将知识库与语料库文本进行启发式对齐生成标注数据，可能会存在两个问题：

（1）通过远程监督生成的标注数据可能不正确。例如句子 4 属于负样本，实体“Donald Trump”与“United States”之间实际上没有语义关系，但利用远程监督假设可以将其视为“Born in”或“President of”关系，属于错误标注。这种标注错误的数据被称为假阳性数据， Riedel 等人在使用 FreeBase 知识库与纽约时报文本启发式对齐获取标注训练数据时，发现有超过 31%的训练数据属于假阳性数据。

（2）知识库中的实体对存在多个关系标签，仅仅通过实体启发式对齐不能确定句子中的实体属于哪种关系标签。例如知识库中实体对“Donald Trump”与

“United States”之间存在两个关系标签，仅仅通过远程监督不能确定句子 1 和句子 3 属于“President of”关系，句子 2 属于“Born in”关系。而在 Riedel 等人生成的语料发现，有大约 7.5%的实体对含有两个或两个以上的关系标签。

以上两种问题都归为远程监督关系抽取存在的噪声标注问题，然而，这些噪声标注数据同样会添加到训练数据集中进行关系分类器的训练，从而导致错误传播，降低了关系抽取的准确率。因此，如何有效地过滤噪声标注数据，是提高远程监督关系抽取效果的研究重点。

2.3.2 相关降噪方法

针对远程监督关系抽取方法容易产生噪声标注数据的问题，不少学者提出了不同的降噪方法，这些方法可以归纳为以下三种方案：基于 at-least-one 假设、层次主题模型以及模式匹配原则。

（1）基于 at-least-one 假设

由于远程监督方法提出的假设过于严格，基于 at-least-one 假设的关系抽取方法提出了一种更加宽松的语义假设：若一对实体包含某种特定关系，则至少有一个含有这对实体的语句属于这种关系。一般来讲，原始远程监督方法认为所有含有相同实体对的语句都隐约地表现出同一种语义关系，但是如果知识库与进行启发式对齐的语料库的来源完全不同时，该方法就会产生大量的噪声标注数据。而基于 at-least-one 假设的方法放宽了原始假设的限制，认为所有包含相同实体的语句中至少有一个句子表达了实体对在知识库中对应的关系。如果关系实例中的两个实体在语料库进行启发式对齐只能获得一个句子时，则 at-least-one 假设等同于原始假设。研究发现， FreeBase 知识库中大约有 92%实体对在维基百科语料库中只出现一次。

基于 at-least-one 假设，相关学者分别提出了不同的关系抽取方法，用来过滤远程监督过程中产生的大量错误标注数据。Riedel 等人首先根据 at-least-one 假设提出了一种由因子图构成的关系抽取模型，将关系抽取过程看作是一个多实例学习的过程。该模型首先将两个实体的关系向量与一组二元关系变量连接起来，通过这些二元变量指示候选句子集是否表达了某种关系，然后为每个实体对标记一个知识库存在的关系标签或无任何关系的 NIL 标签（表明语料中的实体对在知识库中没有关系对应）。如果因子图中存在不属于 at-least-one 假设的因子，则通过目标函数对该因子增加惩罚权重，最后使用具有感知器策略的 MultiR

模型进行多元关系分类。Surdeanu 等人[36]对 MultiR 模型展开进一步扩展，提出了一个联合训练的多实例多标签关系抽取模型-MIMLRE 模型。该模型主要由一个多标签分类器和一组二元分类器所构成，首先使用多标签分类器对句子进行多类型预测，然后将预测结果输入到二元分类器中确定实体对之间的特定关系类型。通常情况下，基于 at-least-one 假设的方法需要一定的负例样本对 NIL 标签进行训练，使得关系模型能够准确的识别出没有任何关系的句子实例。

（2）层次主题模型

基于层次主题模型的降噪方法的主要目标就是将语料中语句的上下文分布进行分层，该模型认为通过知识库与语料库文本进行启发式对齐获得的标注语句可能是由实体对生成的，也有可能是由关系生成的，或者是由其他形式生成的。三种生成方式对应三种不同上下文分布，分别为实体对匹配的特定实体分布（Pair-Specific Distribution）、关系匹配的特定关系分布（Relation-Specific Distribution）以及其他形式匹配的狄利克雷分布（Dirichlet Distribution）。假设上下文语句的生成过程是针对某个特定实体对，那么在为特定实体分布选择隐含参数时，所有包含该实体分布的生成模型都已经提前生成。生成模型的主要任务就是确定句子中的两个实体之间的关系类型，通过计算上下文语句与所有关系之间的概率，判断句子中实体对属于哪种关系。

与基于 at-least-one 假设的方法相比，层次主题模型主要是通过一种高效可行的方法对能够表达句子语义关系的上下文语句进行分类。同时，层次主题模型通过特定分布模型获得的上下文局域数量只与知识库中的关系标签相关，与其他因素无关[43]，而且该方法也不需要特定的负例样本对 NIL 标签进行训练。

（3）模式匹配原则

基于模式匹配原则的降噪方法主要是根据语句的生成方式构建语法结构模式，然后通过模式匹配的方式判断该模式属于哪一种关系类型。Takamatsu 等人[44]认为语法结构模式是由实体的实体类别和依存句法解析树上两个实体之间的短语序列所构成。例如，从“The European Union is located in Brussels, Belgium.”中可以抽取出语法结构模式为“[Organization] is located in [Location]”。其中，[Organization]表示头实体的实体类型，[Location]表示尾实体的实体类型，通过[Organization]和[Location]约束了语法模式中头实体的类型必定是组织，尾实体的类型必定是位置。如果语法模式中两个实体的类型有一个不匹配，那么句子所表达的关系就不同，这样就能够将两个拥有相同的依赖路径却表达不同关系的句子进行区分。该降噪方法的生成模型原理可以归纳为：如果通过语法分析得到

句子的语法模式 p 和参数 i 组成的三元组结构，那么是由于以下几种原因产生的：

① 语法模式 p 能够表达出关系 r，即$\theta_{rp} = true$；

② 语法模式 p 不能表达出关系 r，但是其他语法模式 q 表达了关系 r 且模式 q 的参数 j 包含了模式 p 的参数 i，即 $\theta_{rq} = true(i \in j)$；

③ 语法模式 p 不能表达出关系 r，说明该句子属于噪声数据。

与层次主题模型类似，基于模式匹配的方法同样存在一个隐藏层参数θ_{rp}，用来判断关系模式 p 是否能够表达出关系 r。但与层次主题模型不同的是，基于模式匹配的方法可以根据不同的语法形式对关系模式进行分组，并且不会关注关系模式出现重复的情况。

2.4 本章小结

本章主要是对远程监督关系抽取方法做出了详细的分析，首先对远程监督方法的原理进行整理归纳，然后分别从启发式对齐、特征提取、训练分类器以及关系抽取四个步骤介绍了远程监督关系方法的流程，最后结合具体的实例分析了远程监督关系抽取方法存在的噪声标注问题，并对基于“at-least-one 假设”、层次主题模型以及模式匹配原则三种常见的降噪方法进行了描述。

第 3 章 基于语义相似度的远程监督噪声标注过滤方法

通过上一章对远程监督关系抽取方法的分析，可以发现，远程监督方法在获取标注语料的过程中会很容易产生噪声标注数据。如果这些噪声数据没有经过降噪处理，就当作训练数据对关系抽取模型进行训练，很可能会模糊关系抽取模型的边界，从而降低关系抽取的效果。为了能够有效地降低噪声标注数据对实验结果的影响，本章提出了一种基于语义相似度的远程监督噪声标注过滤方法，通过计算句子中实体对之间的最短依存路径与关系短语之间的语义相似性来判断标注语句是否被正确标注，然后将过滤后的标注数据使用分段卷积神经网络关系模型进行关系分类。

3.1 基于语义相似度的噪声标注过滤框架

由于远程监督关系抽取方法在自动标注关系标签过程中，存在大量的噪声标注问题，因此如何有效地过滤噪声标注数据，是提高远程监督关系抽取效果的研究重点。本章将提出一种基于语义相似度的噪声标注过滤方法，减少远程监督过程中的错误标注数据，方法框架如图 3-1 所示。

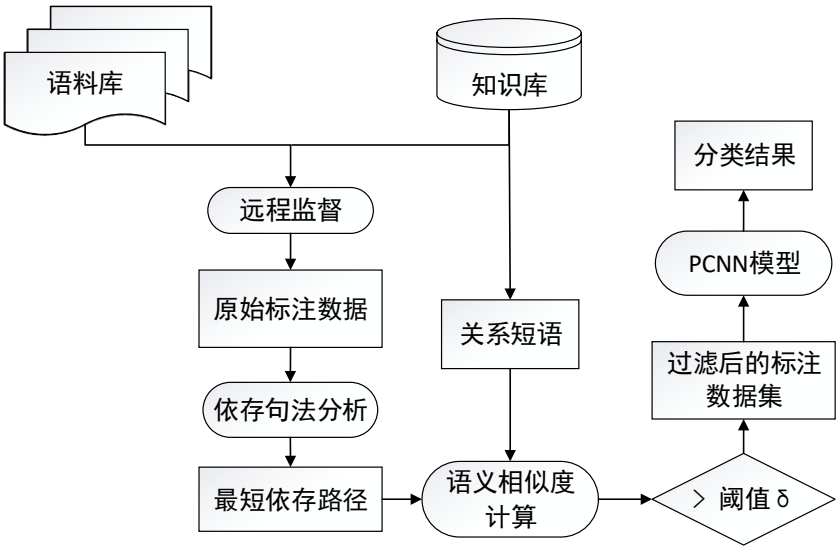

图 3-1 基于语义相似度的噪声标注过滤框架

该方法的具体步骤如下：

（1） 给定的目标语料库和知识库，使用远程监督的方法标记训练数据并获得原始标注数据；

（2） 对原始标注数据使用自然语言处理工具进行依存句法分析，获取句子中实体对之间的最短依存路径；

（3） 通过计算句子实体对之间的最短依存路径与关系短语的语义相似性来确定该标注语句是否属于噪声标注数据，语义相似度越低，该句子被正确标注的可能性就越小；

（4） 选择语义相似度不小于阈值 δ 的句子作为输出正例添加到训练数据集中，并将过滤后的标注数据输入到 PCNN 模型中进行关系分类。

3.2 最短依存路径的获取

3.2.1 依存句法分析

要想获取原始标注语句的最短依存路径，首先需要对句子进行依存句法分析。在自然语言处理过程中，依存句法分析是获取句子语法信息的关键步骤，其主要目标是确定句子中词汇之间在语法上支配与被支配的有向关系（即词汇间依存关系），同时通过分析词汇间的依存关系揭示句子的句法结构和语法结构。依存句法分析将句子中的核心谓词作为句法结构的中心成分，而其他语法成分都会直接或间接地受到核心谓词支配。依存句法结构通常有依存图和依存树两种表现形式，依存图描述了句子中词汇之间有向关系（如图 3-2(a)），而依存树则描述了词汇之间支配与被支配的关系（如图 3-2(b)）。

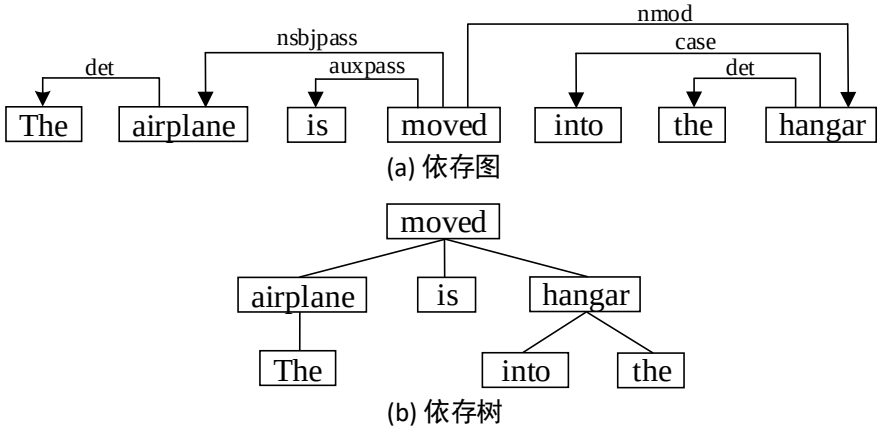

图 3-2 依存句法结构示意图

计算语言学家 J.Robinson 对依存句法中词汇之间的依存关系提出了四条原则：①一个句子中只含有一个核心语法成分；②句子中的其他语法成分直接依存于核心语法成分；③句子中的任何一个语法成分只能依存于一个语法成分；④如果语法成分 C 位于语法成分 A 和 B 之间，那么 C 直接依存于 A 或 B，或者依存于它们之间的某一语法成分。这四条原则直接对句子的依存句法结构做出了严格的限制，从而保证句子的依存句法分析结果是一个连通、无环、只有一个根节点的树形结构。

3.2.2 最短依存路径

由于有些语句过长且结构复杂，仅仅通过依存句法分析很难确定句子的语义关系。因此，Bunescu 等人[45]提出了最短依存路径的概念，用来明确实体对之间的关系结构，并且指出两个实体之间的最短依存路径能够提取出包含句子关键语义信息的短语序列。例如，在已经识别出实体的例句“A hundred tons of [airplane] has been moved into an empty [hangar] of outer space”进行依存句法分析，图 3-3 显示了该例句依存路径结构树示意图。图中实箭头指向的路径表示句子中两个实体之间的最短依存路径，它是由实体所在子节点向上回溯到根节点的两个依存句法子树所构成，两个子树分别为“tons →of →airplane →moved”和“moved ←into ←hangar”，其中 a→ b 表示 a 依存于 b。由图 3-3 可以发现，最短依存路径上的短语序列[tons of airplane moved into hangar]蕴含着大量能够确定实体语义关系的重要信息。而句子的其他词汇大多属于两个实体或核心谓词的修饰词，蕴含的语义信息不多。在关系抽取过程中，如果这些词汇没有得到适当的处理，很可能降低关系抽取的效果。

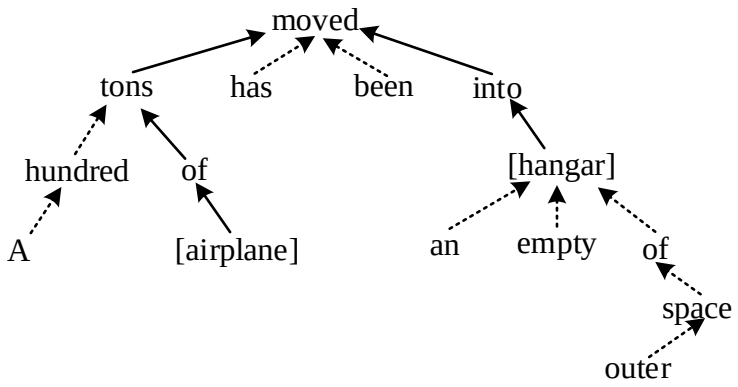

图 3-3 例句的依存路径结构树示意图

最短依存路径可以通过依存句法分析树所获得,其中包含的短语序列以及实体对之间的依存关系都是确定两个实体之间语义关系的重要信息，而且其还能排除句子中冗余句法信息对关系判断的影响。因此，本章将使用最短依存路径代替整个句子与关系短语进行语义相似度计算。

3.3 基于词向量的 Jaccard 相似度计算方法

为了计算句子中两个实体间的最短依存路径与关系短语的语义相似度，本章将采用一种基于词向量的 Jaccard 相似性度量方法，首先简要介绍一下传统 Jaccard 算法相关理论知识。

3.3.1 传统 Jaccard 相似度计算方法

Jaccard 算法是一种常用的相似性度量方法，该方法主要通过句子词汇的重叠程度判断两个句子的相似程度，如果两个句子的词汇重叠程度越高，这两个句子的相似性就越高。通过计算共现词汇在句子中的比例判断两个句子之间的相似度，计算方法如下：

$$Sim(X,Y) = \frac{\|\cap(X,Y)\|}{\|\cup(X,Y)\|} \tag{3-1}$$

其中，$\cap(X,Y)$用来计算两个句子X,Y的所有词汇交集，$\cup(X,Y)$ 用来计算两个句子X,Y的所有词汇并集。

由于上述算法未考虑交集词汇在句子中的重要程度，有学者对此提出了基于 TF-IDF 技术改进的 Jaccard 相似度计算方法。该方法不但体现了原始 Jaccard 算法共现词原理，而且为每一个交集词汇赋予不同的词频权值（即 IDF 值），具体公式表达如下：

$$Sim(X,Y) = \left(\sum_{w\in\ \cap(X,Y)} log\frac{N}{df_w}\right)\frac{\|\cap(X,Y)\|}{\|\cup(X,Y)\|} \tag{3-2}$$

$\left(\sum_{w\in\ \cap(X,Y)} log\frac{N}{df_w}\right)$表示在句子$X,Y$交集词汇中为每个词汇$w$赋予一个$IDF$权值，其中，N 为数据集中句子实例总数，$df_w$为出现词汇$w$的句子实例数，$\log N/df_w$为词汇$w$的逆文档频率 IDF 值。不难发现，交集词汇的重要程度越高，其赋予的权值越高，对相似度计算的影响也就越大。

3.3.2 基于词向量的 Jaccard 语义相似度计算方法

不管是原始的 Jaccard 算法，还是采用词汇权重扩展后的 Jaccard 算法，其核心思想仍然是通过计算两个句子词汇的共现程度来衡量的它们之间相似度。如果两个句子词汇的共现程度越高，那么这两个句子的相似性越高。但是在相似性计算过程中存在一个比较大的问题，传统的 Jaccard 算法没有考虑词语蕴含的语义信息，不能将同义词和近义词作为共现词汇进行计算。如果两个句子是由语义相近的词汇组成，在计算句子相似性的过程中，同义词和近义词将会被排除在计算范畴之外。

针对语义层面的相似度计算，不少学者采用基于语义词典（如 WordNet、HowNet、同义词林等）的相似度计算方法[46-47]进行研究，该方法充分利用语义词典中的同义词集和语义关系结构，通过计算两个句子中每个词汇的语义相似度衡量句子之间的相似性。基于语义词典的相似度计算方法虽然在实际应用中取得了可观的效果，但是该方法过度依赖所使用的语义词典，词典的质量决定了相似度计算的效果，同时对于词典中未登录词汇的相似度计算结果有着较大的误差。

随着深度学习技术在自然语言处理领域的深入研究，词向量得到了广泛的应用。词向量是一种通过对语言模型中的词汇进行分布式表达的词表示方法，通过训练可以将词语映射到一个高维的空间向量。Mikolov 等人[48]在训练词向量时发现，$v(Paris)-v(France)+v(Italy)\approx v(Rome)$，由此可以说明词向量本身蕴含的语义信息能够直接作为词语相似度计算的依据。因此，本章将采用基于词向量的 Jaccard 的相似性度量方法计算标注句子中两个实体之间的最短依存路径与关系短语之间的语义相似度，该方法将原始 Jaccard 算法中的词汇共现程度转化为词向量的共现程度。具体计算方式如下：

$$\mathrm{Cosine}(a,b)=\frac{a\cdot b}{\|a\|\times\|b\|}=\frac{\sum_{i=1}^{n}a_i\times b_i}{\sqrt{\sum_{i=1}^{n}(a_i)^2}\times\sqrt{\sum_{i=1}^{n}(b_i)^2}} \tag{3-3}$$

$$Sim(S,T)=\frac{\sum_{w\in S}min(max(\lambda\times Cosine(w,T)),1)+\sum_{w\in T}min(max(\lambda\times Cosine(w,S)),1)}{|S|+|T|} \tag{3-4}$$

公式 3-3 中，$\mathrm{Cosine}(a,b)$表示词汇a和b在词向量表中对应的词向量之间余弦相似度。公式 3-4 中，S，T 表示两个需要计算语义相似度的句子，$max(\lambda\times Cosine(w,T))$表示句子 S 中的词汇$w$与句子 T 所有词汇相对应词向量

之间的余弦相似度的最大值，由于不同词向量模型计算出来的相似度结果有所偏差，因此需要通过参数λ对余弦相似度的放大系数进行调整。由于本章采用 Google 开源的词向量工具 word2vec 预训练好的词向量，参数λ可取值为 1。

基于词向量的 Jaccard 相似性度量算法的核心思想是通过计算句子词汇的语义相似性衡量词汇之间的相似度，虽然从本质上与基于语义词典的方法有相似之处，但是通过词向量表示的语义范围比语义词典更加广泛。例如，“teach”和“teacher”在语义词典中无法查到对应的关系，计算这两个词汇对应词向量之间的余弦相似度却达到了 0.513。可见，基于词向量的相似度计算方法解决了语义词典不可扩展的弊端。

3.4 基于分段卷积神经网络的关系抽取模型

在基于深度学习的自然语言处理任务中，卷积神经网络模型得到了非常广泛的应用，由于卷积神经网络模型能够保留句子的局部关键信息，本节将采用基于分段卷积神经网络的关系抽取模型对过滤后的标注数据进行关系抽取，图 3-4 展示了分段卷积神经网络关系抽取模型的内部结构：

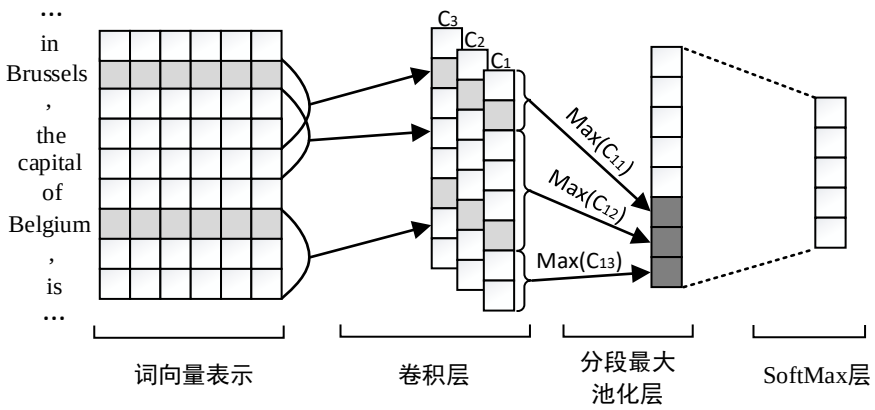

图 3-4 分段卷积神经网络关系抽取模型

该模型首先将句子进行词向量表示，然后从左到右用一个滑动窗口进行扫描，滑动窗口矩阵的每一行对应句子的一个单词（或一个字符）。在滑动窗口内，通过卷积层提取特征，再通过池化层采用分段最大池化策略选择局部关键特征。通过多次卷积和池化操作，将得到的多个向量进行级联获取完整的句子向量表示。最后将句子的向量表示通过 SoftMax 层进行归一化，得到关系分类结果。下面将对模型各层的功能展开详细介绍：

（1）词向量表示层

词向量表示层的主要作用是通过查询 lookup 表（词与对应词向量的映射表）将句子中的词语映射成词向量，句子的词向量表示可以获取整个句子的高层语义信息。其中，词向量可以是事先在语料库训练好的，也可以是随机初始化后再训练过程中不断更新的。本节将使用由 Mikolov 等人训练出来的 word2vec 词向量，与其他的单词分布式表示方法（如 one-hot 编码）相比，word2vec 词向量维度更低，包含更丰富的语义信息。

（2）卷积层

在关系抽取任务中，卷积层的主要作用是通过卷积操作提取出句子的局部特征信息。假设$S = \{x_1, x_2, \dots, x_i, \dots x_m\}$为有 m 个单词数的句子表示，$x_i$表示句子 S 第 i 个单词的向量表示。定义$x_{i:j}$表示词序列$[x_i: x_j]$的向量拼接，k 为卷积核滑动窗口的长度。为了捕获句子中的不同特征信息，通常会在卷积过程中采用多个卷积核，假设卷积核矩阵为$\mathbf{U} = \{U_1, U_2, \dots, U_n\}$，其卷积运算过程为：

$$c_{ij} = \ U_i \oplus \ x_{j-l+1:j} \quad (1 \le i \le n, 1 \le j \le m + k - 1) \qquad (3\text{-}5)$$

其中，k 表示滑动窗口的大小，n 表示卷积核的数量。

（3）分段最大池化层

池化层主要作用是对卷积层获得的特征信息进行的深入提取，从而捕获句子信息中关键特征。池化层使用的池化方法主要包括最大池化、平均池化和随机池化三种，其中最大池化方法在各种自然语言处理任务上最为常用。最大池化方法是在每一个卷积核提取的特征中选取最大值，获取句子中最重要的特征信息。

但在关系抽取任务中，最大池化方法过于粗糙而无法捕获到关系提取的细粒度特征，单一的最大池化操作不足以获取两个实体间的结构信息。因此，本章采用分段最大池化方法，将每个卷积核提取的特征向量c_i以实体对为中心，切分为$\{c_{i1}, c_{i2}, c_{i3}\}$三段，然后对每段特征向量做最大池化操作：

$$q_{ij} = max\left(c_{ij}\right) \quad 1 \le i \le n, 1 \le j \le 3 \qquad (3\text{-}6)$$

最后，将三个通过最大池化操作向量集合$\{q_{i1}, q_{i2}, q_{i3}\}$输入到双曲正切函数中进行运算，输出得到最终结果：

$$s = tanh(q_{1:n}) \qquad (3\text{-}7)$$

（4）SoftMax 层

SoftMax 层的主要作用是将句子向量进行归一化，转换成各个关系类型的概率分布。SoftMax 分类器的计算公式如下所示：

$$p_i = \frac{exp(z_i)}{\sum_{i=1}^{n} exp(z_i)} \ (i=1,2,\ldots,n) \qquad (3\text{-}8)$$

假设最终的关系类型共有 n 类，p_i表示属于第 i 类关系标签的概率分布，其中,$z = W_s X + b \ \in \ R^n$，$X$ 表示最大池化层输出的句子表示，W_s为权重矩阵，b 为偏置值。

为了学习 PCNN 模型的网络参数，本节将使用随机梯度下降（SGD）的方法对损失函数进行优化，损失函数将采用负对数似然函数：

$$J(\theta) = \ -\sum_{i=1}^{n} logp(y^{(i)}|x^{(i)},\theta) \qquad (3\text{-}9)$$

其中，θ表示 PCNN 模型中的所有需要学习参数，模型训练的目标就是最小化负对数似然函数$J(\theta)$。

3.5 实验准备

3.5.1 语料库和知识库

从基于语义相似度的噪声过滤方法框架中可以看出，语料库和知识库在远程监督关系抽取方法中都发挥着重要作用。

维基百科是一个可以自由访问和编辑的开放式网络百科全书，目前已收集了 301 种语言中数以亿计的文档语料，是世界上文档规模最大、领域范围最广的多语言电子百科全书。作为一个内容可证，来源可信的免费百科全书，维基百科为知识图谱、智能问答等服务的构建提供了安全可靠的数据支持。因此，维基百科被广泛用于计算语言学，信息检索和自然语言处理中的问题研究，本章将选取维基百科英文版作为语料库。

YAGO 是一个大型语义知识库，主要由维基百科，WordNet 和 GeoNames 自动构建而成。 该知识库结合了来自维基百科的 10 种不同语言的信息，使包含的知识具有多语言维度。它还将时间和空间信息附加到许多知识事实上，从而允许用户在时间和空间维度上查询数据。 YAGO 专注于提取质量，手动评估精度高达 95%。目前，YAGO 已经包含超过 1000 万个实体和超过 1.2 亿个关系实例。

因为 YAGO 中大部分知识数据来源于维基百科，所以 YAGO 中的关系实例更容易出现在维基百科文本中。为了获取足够多的标注数据，本章将选用 YAGO 作为知识库。

为了验证基于语义相似度的降噪方法在远程监督过程是否能够有效地过滤噪声标注数据，本章从 YAGO 知识库中已知的 96 种关系类型选取了 10 种具有代表性的关系标签进行实验。这 10 种关系标签中有的能够表达出多种语义，有的包含的实体对在语料库中存在多个关系标签，容易引起噪声标注的问题。由于维基百科语料库中有些句子结构复杂其句子长度过长，本章还将过滤掉句子长度小于 3、大于 80 的句子实例。表 3-1 列出了这 10 种关系标签以及对应的句子实例数量。

表 3-1 关系标签及句子数量

关系标签	句子数量	关系标签	句子数量
deal_with	9617	was_born_in	22158
is_leader_of	6573	is_affiliated_to	8925
works_at	15231	happen_in	5619
directed	7614	is_capital_of	28573
lives_in	18627	is_interested_in	12136

3.5.2 实验设置

实验环境：操作系统 Windows10，64 位；处理器 Intel(R) Xeon(R) CPU E3-1225 v5@3.30GHz；内存 16G；编程平台 Pycharm，Python3.6 版本。

评估标准：本章主要采用准确率、召回率、F 值作为评价指标，用来评估提出的降噪方法是否有效。准确率、召回率和 F 值的计算公式如下：

$$precision = \frac{out_right}{out_all} \tag{3-10}$$

$$recall = \frac{out_right}{test_all} \tag{3-11}$$

$$F_score = \frac{2 * precision * recall}{precision + recall} \tag{3-12}$$

其中：out_right表示输出中预测正确的关系数量，out_all表示输出中总共的关

系数量，$test_all$表示测试集中总共的关系数量。

参数设置：该部分参数设置主要针对 PCNN 模型的参数进行设置，句子的词向量表示使用预训练好的词向量表进行初始化，词向量表采用 google 开源的 word2vec 工具对英文维基百科进行训练，PCNN 模型的主要参数设置如表 3-2 所示：

表 3-2 PCNN 模型的主要参数设置

参数	参数值
词向量维数	300
句子的最大长度	80
滑动窗口大小	3
批样本大小	50
迭代次数	100

3.6 实验设计与结果分析

3.6.1 不同相似度计算方法对比

在计算句子中最短依存路径上的短语序列与关系短语之间的语义相似度时，本章采用的是基于词向量的 Jaccard 相似性度量方法（简称为 WE-Jaccard 方法），为了验证该方法的有效性，该实验部分将与以下两种常用的相似性度量方法进行对比：

Jaccard 方法：传统的 Jaccard 相似性度量方法，通过两个句子短语的共现词重叠程度计算相似度。

Cosine 方法：余弦相似性度量方法，首先将句子短语转化为对应的词向量，然后计算两个短语词向量的的夹角余弦值来衡量它们之间的相似度。

为了评估不同相似度计算方法的效果，从上述 10 种关系类型包含的句子实例中根据关系类型分为 10 组，每组分别人工挑选出与对应关系标签具有语义相似性的 100 个句子实例作为实验数据，然后使用不同的相似性度量方法计算每个句子中实体之间的最短依存路径与关系短语的语义相似度，最后将每种关系类型的 100 个相似度结果取平均值，作为最终的计算结果。实验结果如图 3-5 所示：

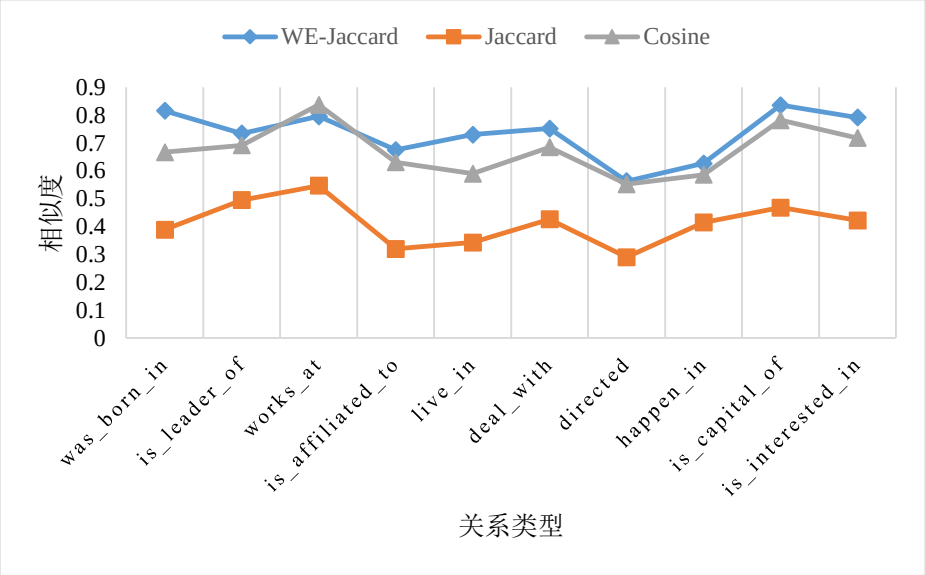

图 3-5 不同方法在不同关系类型的语义相似度

通过以上 10 种不同关系类型的对比实验可以看出，在三种不同的相似性计算方法，WE-Jaccard 方法获得的相似度最高，Cosine 方法次之，Jaccard 方法最差，说明本章提出了基于词向量改进的 Jaccard 方法对于计算句子短语之间的语义相似度更加有效。同时，词向量蕴含着词汇的语义信息，能够明显地提升相似性度量方法的计算性能和效果。

3.6.2 最优相似度阈值 δ 确定

在本章提出的基于语义相似度噪声标注过滤方法中，相似度阈值 δ 对于过滤噪声标注数据起到了十分重要的作用，阈值 δ 取值的优劣直接决定了标注数据的质量。为了获取该方法的最优相似度阈值，本节实验首先确定不同相似度区间对应的句子实例数，使用基于词向量的 Jaccard 方法计算所有的句子实例与关系短语之间的语义相似性，然后对不同相似度区间的句子实例进行统计，统计结果如图 3-6 所示。

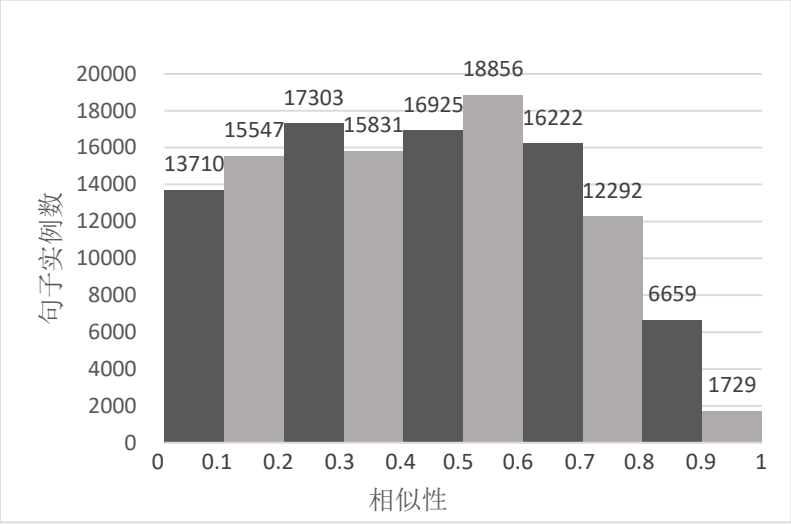

图 3-6 不同相似度对应的句子实例数

从图 3-6 可以看出，句子实例主要集中在相似度[0.1,0.7]之间，其中[0.5,0.6]区间内句子实例数相对较多；在相似度区间[0,0.1]内也包含了不少句子实例，说明通过远程监督启发式对齐获取的标注数据确实存在噪声标注现象；在相似度区间[0.5,1]内，随着相似度递增，过滤后的标注数据质量也不断提高，但是句子实例数却不断减少。针对不同相似度区间的句子实例数，该实验部分还设计了 10 组不同的相似度阈值 δ 实验，分别将 δ 设置为 0.0、0.1、0.2、0.3、0.4、0.5、0.6、0.7、0.8、0.9，选取语义相似度不小于 δ 的句子实例集合作为训练数据输入到 PCNN 模型中进行训练，然后使用测试数据进行实验，最后采用 F 值作为评估标准，实验结果如图 3-7 所示：

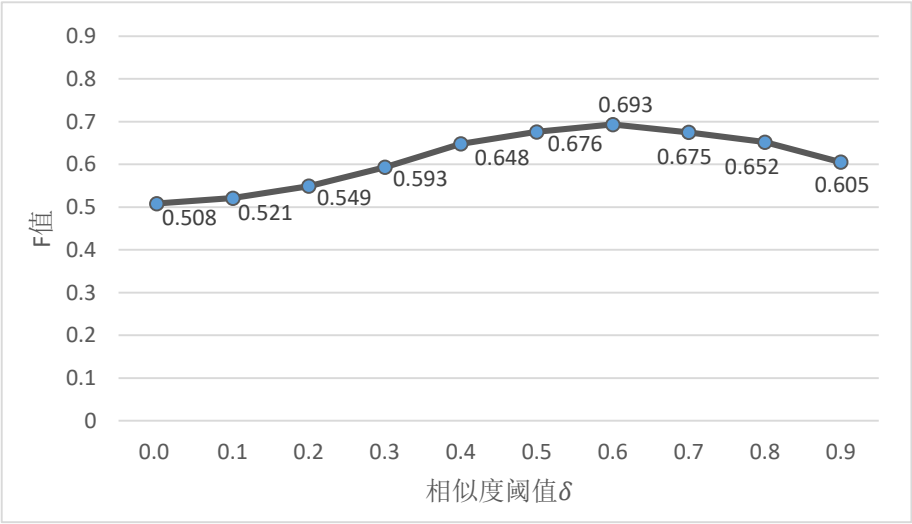

图 3-7 不同相似度阈值下 F 值大小

从图 3-7 可以看出，F 值首先随着相似度阈值 δ 的增大而增加，当 δ 为 0.6 时，F 值达到最大值（即 δ=0.6 为最优相似度阈值），当 δ 大于 0.6，F 值随之降低。该实验证明了相似度阈值的设定对于过滤噪声标注数据起到了重要作用，设置相似度阈值时，需要兼顾训练样本的质量和数量，阈值过低，则噪声过滤效果不明显，使得准确率降低；阈值过高，则会将正确标注的语料过滤，降低了召回率。

3.6.3 噪声数据过滤效果对比

为了验证本章提出的基于语义相似度的降噪方法在远程监督关系抽取中的表现，将采用表 3-3 中的四种不同方法进行关系抽取效果对比。其中训练数据分为两类，一类为通过启发式对齐获取的原始标注数据，另一类为使用本章提出的基于语义相似度的降噪方法过滤后的标注数据（最优相似度阈值 δ=0.6）。

表 3-3 实验方法介绍

方法名	关系抽取模型	训练数据
Mintz	Mintz 提出的采用 L-BFGS 优化的多元逻辑回归模型[33]	原始标注数据
F-Mintz		降噪后的标注数据
PCNN	分段卷积神经网络关系抽取模型	原始标注数据
F-PCNN		降噪后的标注数据

分别比较四种方法在不同训练数据集上的准确率、召回率和 F 值，实验结果如表 3-4 所示：

表 3-4 不同实验方法的关系抽取效果

方法	准确率	召回率	F 值
Mintz	0.357	0.386	0.371
F-Mintz	0.532	0.525	0.528
PCNN	0.52	0.496	0.508
F-PCNN	0.709	0.678	0.693

从表 3-4 的对比实验可以发现，相较于 Mintz 和 F-Mintz 方法、F-PCNN 和 PCNN 方法，F-Mintz 和 F-PCNN 方法的关系抽取效果明显优于 Mintz 和 PCNN 方法，F 值都分别有了 15.7%和 18.5%的提高，这说明了采用语义相似度的方法进行远程监督噪声标注数据过滤是有效的，可以显著提高关系抽取的效果。同时，

无论是在原始标注数据集上还是在降噪后的标注数据集上，采用 PCNN 模型进行关系抽取的效果都要优于 Mintz 提出的多元逻辑回归模型，这是因为 PCNN 模型在提取句子特征时保留了句子的局部关键信息，相较于传统的特征工程方法，更能够捕获到句子的局部关键特征。

3.7 本章小结

本章主要针对传统远程监督关系抽取方法容易产生噪声标注数据问题，提出了一种基于语义相似度的噪声标注过滤方法，通过计算句子实例的最短依存路径上的短语与关系短语的语义相似度来判断标注数据是否被正确标注。该方法主要分为三个层面：句子的最短依存路径获取、基于词向量的 Jaccard 相似性度量方法和分段卷积神经网络关系关系抽取模型。首先对句子结构进行依存句法分析获取句子的最短依存路径，然后在传统 Jaccard 计算方法上提出了基于词向量的 Jaccard 相似性度量方法，用于衡量最短依存路径上的短语与关系短语的语义相似度，从而判断标注数据是否被正确标注，最后将过滤后的标注数据输入分段卷积神经网络关系抽取模型进行关系分类。通过实验结果验证了本章提出的降噪方法对于过滤远程监督噪声标注数据是有效的。

第 4 章 基于多层次注意力机制的远程监督关系抽取模型

由于深度学习技术无需复杂的特征工程就能自动学习句子特征，从而避免了传统自然语言处理方法造成的错误传播问题。本章将结合深度学习技术，提出一种融合多层次注意力机制远程监督关系抽取模型，进一步提高实体关系的抽取效果。

4.1 基于注意力机制的关系抽取方法

4.1.1 注意力机制相关理论

近年来，随着深度学习的研究不断深入，深度学习技术在各个领域都取得了不少突破性的成果。基于注意力机制的神经网络在计算机视觉和自然语言处理等领域的不错表现也得到了越来越多学者的关注，不少研究者将注意力机制成功应用在图像识别、机器翻译和文本处理等领域。

注意力机制是由 Treisman 和 Gelade 提出的一种模拟人脑注意力的模型，通过计算概率分布突出关键输入信息对输出结果的影响，并以此来优化模型。其最早应用于视觉图像处理领域，其本质与人类的选择性视觉注意力机制类似，不是将所有注意力集中在整幅图像，而是关注那些关键性部分，凸显关键部分的重要性。于是 Google Mind 团队于 2014 年在 RNN 模型中引入注意力机制进行图像分类任务[49]，成功验证了注意力机制在图像处理过程中的促进作用。同年 Bahdanau 等人[50]首次将注意力机制应用在自然语言处理任务中，采用注意力机制对机器翻译模型进行优化。而后，基于注意力机制的神经网络模型被广泛运用到自然语言处理任务中。图 4-1 展示了注意力机制近几年来的发展过程。

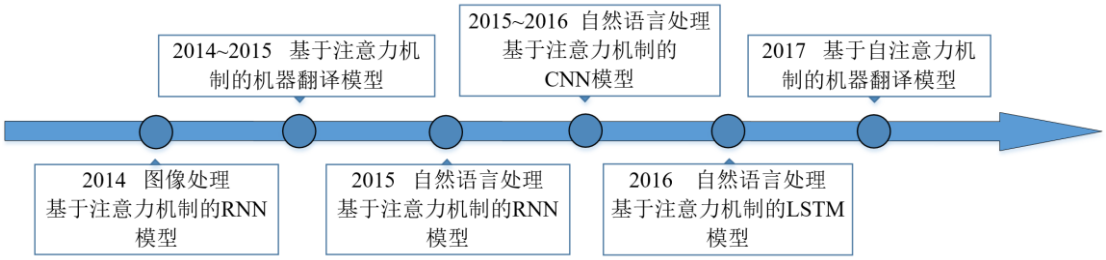

图 4-1 注意力机制发展时间轴

在自然语言处理任务中，注意力机制通常应用在端到端的序列模型中，例如，常见的编码解码（Encoder-Decoder）框架。在由输入序列生成输出序列的过程中，注意力机制首先通过计算源文本上下文不同词语的概率分布，分配给输入序列词语不同的注意力权重，然后根据输入序列中词语的注意力权重来生成输出序列。其模型示意图如图 4-2 所示：

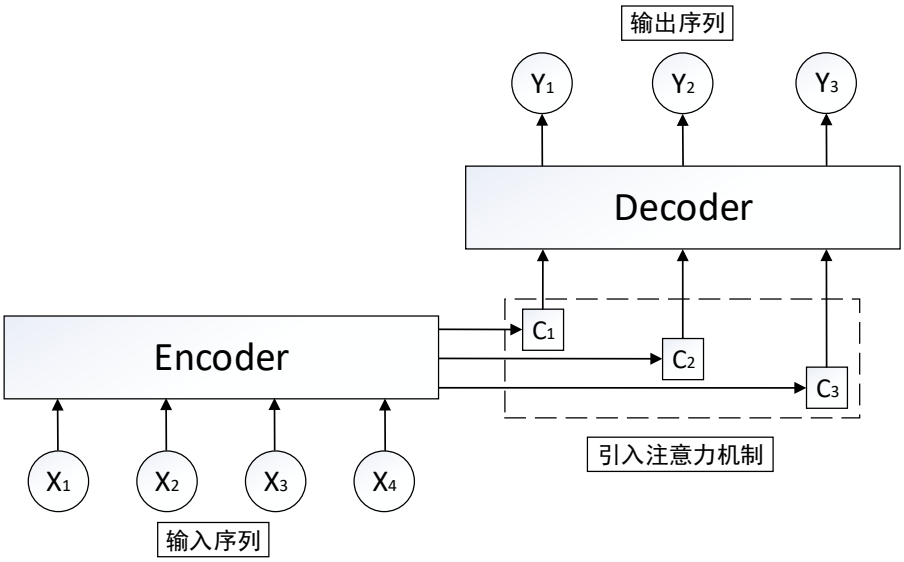

图 4-2 Encoder-Decoder 框架引入注意力机制

由此得到的输出序列可由以下公式表示：

$$y_1 = f(C_1) \tag{4-1}$$

$$y_2 = f(C_2, y_1) \tag{4-2}$$

$$y_3 = f(C_3, y_2, y_1) \tag{4-3}$$

其中，y_i为输出序列词语，f 为输入序列的非线性变换函数，C_i为输入序列不同词语的注意力权重，注意力权重C_i通常采用公式（4-4）进行计算：

$$C_i = \frac{\exp(g(x_i,x_j))}{\sum_{k=1}^{l}\exp(g(x_k,x_j))} \tag{4-4}$$

其中，g 为权重计算函数，用于将输入序列中需要计算权重的词语向量x_i与影响其权重的词语向量x_j联系起来，l 表示输入序列所有词语向量个数，C_i采用 Softmax 函数进行归一化，使得所有输入序列的词语向量权重加起来和为 1。

对于权重计算函数 g，有以下几种常用形式可供选择：

$$g(x_i,x_j) = x_i^T x_j \tag{4-5}$$

$$g(x_i,x_j) = x_i^T W_\alpha x_j \tag{4-6}$$

$$g(x_i,x_j) = W_\alpha[x_i : x_j] \tag{4-7}$$

$$g(x_i,x_j) = v_i^T \tanh(W_\alpha x_i + U_\alpha x_j) \tag{4-8}$$

其中，v_t^T表示权重向量，W_α和U_α为权重矩阵。

在序列模型中引入注意力机制不但可以降低高维数据的计算难度；而且能够根据任务目标的重要性程度自动调整权重，使得模型赋予关键目标更高的权重，从而降低次要目标的噪声影响。

4.1.2 关系抽取任务引入注意力机制

由于注意力机制在自然语言处理领域的出色表现，近年来，不少学者也将注意力机制运用在关系抽取任务上。其中，Lin 等人[39]于 2016 年提出的一种分段最大池化卷积神经网络和注意力机制相结合的远程监督关系抽取模型（Piecewise Convolutional Neural Networks + Attention，PCNN+ATT）。PCNN+ATT 模型以原始远程监督关系抽取的语义假设为基础，使用分段最大池化卷积神经网络提取句子集合的特征，并引入注意力机制减少噪声标注句子实例对整个句子集合关系识别的影响。PCNN+ATT 模型引入注意力机制框架如图 4-3 所示：

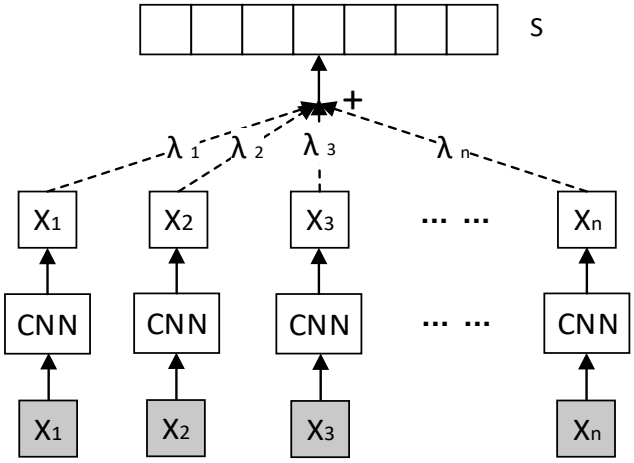

图 4-3 PCNN+ATT 模型引入注意力机制框架

PCNN+ATT 模型的输入是包含相同实体对的句子集合，然后通过分段卷积神经网络对每个句子进行编码获取句子的高层语义表示。但是，句子集合中并不是所有包含同一实体对的句子都有着相同的关系标签，存在一定数量的噪声句子。该模型引入句子层的注意力机制，赋予每个句子向量不同的权重，逐渐降低噪声句子对关系标签分类的影响。最后，将整个句子集合的语义编码输入 Softmax 分类器进行归一化，确定整个句子集合的关系标签。

PCNN+ATT 模型采用分段卷积神经网络获取句子集合的语义特征，并引入注意力机制降低噪声句子的影响，噪声容忍度较高，准确率提高较为显著，是传统基于神经网络框架的远程监督关系抽取方法中一次具有突破性的改进。鉴于 PCNN+ATT 模型引入注意力机制的思想，本章将提出融合多层次注意。力机制的远程监督关系抽取模型，进一步提升实体关系的抽取效果。

4.2 融合多层次注意力的远程监督关系抽取模型

4.2.1 模型整体设计

虽然采用注意力机制优化远程监督关系抽取模型取得了比以往更好的分类效果，但目前大多数研究仅在句子层引入注意力机制，尚未考虑句子中不同词语对实体对的重要程度，以及关系之间的相互依赖包含关系。因此，为了充分结合注意力机制提高关系抽取的效果，本章在采用句子层注意力机制的基础上，通过词语层注意力来充分捕捉实体上下文的语义信息，以及通过关系层的注意力来自动学习关系之间的依赖包含关系，提出了一种融合多层次注意力机制的远程

监督关系抽取模型，其模型结构如图 4-4 所示：首先将句子中所有单词进行词向量表示，并采用双向门控循环网络单元（Bidirectional Gate Recurrent Unit，BGRU）对词向量编码获取句子的高维语义信息；然后通过计算上下文词语和实体对的相关程度，建立词语层的注意力机制进一步捕捉句子上下文的关键信息；通过最大池化层获取句子的向量表示，接着计算句子与关系的相关程度来建立句子层注意力机制，减少标签的错误标注问题；同时，引入关系层的注意力机制来自动学习不同关系之间的相互依赖包含关系，最后将关系表示通过非线性分类器进行分类，从而获取最终的关系抽取结果。

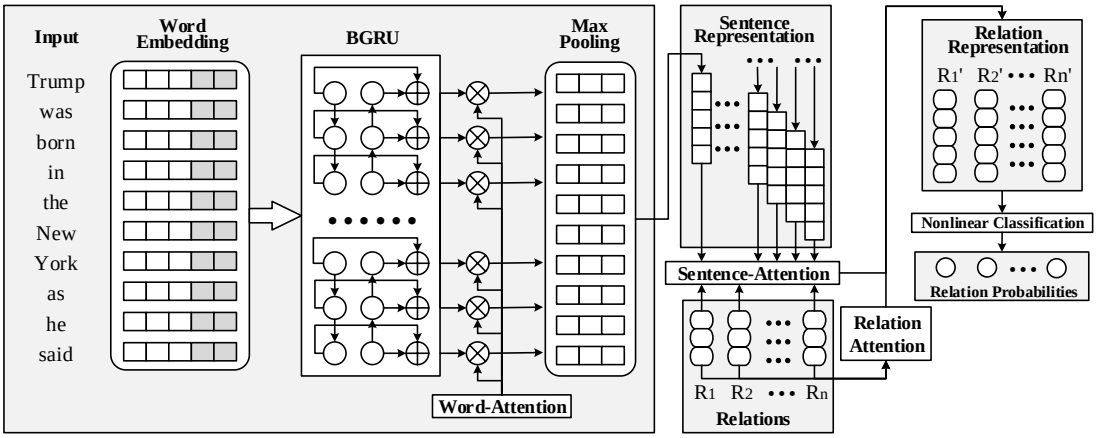

图 4-4 融合多层次注意力机制的远程监督关系抽取模型

4.2.2 基于 BGRU 神经网络的句子向量表示

（1）词向量表示

构建词向量是将句子文本转换为向量形式，每个句子词语转换为一个多维向量矩阵。为了获取句子更好的语义表示能力，本章将采用 word2vec 工具与训练好的词向量，代替传统方法所使用的 One-Hot 词向量。给定一个含有m个词语的句子 S=(w_1，w_2,⋯，w_m)，每个词语w_i都需要经过向量化处理的词向量表示：

$$w_i = W^{word} \times V^w \tag{4-9}$$

其中，$W^{word} \in R^{l\times|m|}$表示采用 word2vec 训练文本的词向量矩阵，l表示词向量的维数(l=300)，m表示句子词语个数；V^w是词语w的 one-hot 表示。

为了能够充分获取句子中词语的句法和语义信息，本文还将采用实体相对位置特征对词向量进行强化表示：

相对位置特征是指句子中词语相对于两个实体的相对距离，主要用于捕获词汇与实体之间的相对位置信息。例如“<e1>Trump </e1> was born in the <e2> New York </e2> just as he has always said.”中，单词“born”到头实体“Trump”的相对距离为 2，到尾实体“New York”的相对距离为-3，并将这两个相对距离进行随机初始化向量表示，形成实体的相对位置向量$w_i{}^a$和$w_i{}^b$。

图 4-5 上下文词语与实体对的相对位置

最后，将词语的词向量与实体相对位置向量进行级联，得到完整的词向量表示。

（2）句子向量的 BGRU 编码

为了能够充分获取句子的高维语义表示，以及解决句子的长距离依赖问题，本文采用双向 GRU 模型对输入的词向量进行编码。GRU 模型是 Chuang 等人[51]提出的一种 LSTM 模型的变种，既保持了 LSTM 的训练效果，又简化了 LSTM 的内部结构，而且提高了模型训练速率。它包含更新门和重置门两个门结构和一个隐藏状态，其内部结构如图 4-6 所示。

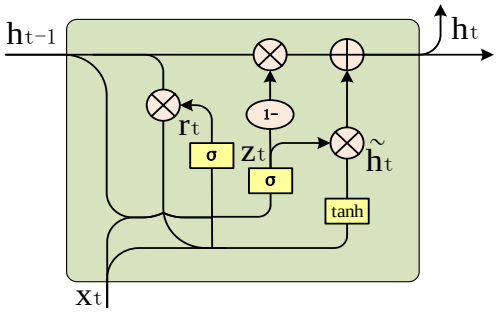

图 4-6 GRU 模型内部结构

以句子第 t 个词语的词向量$x_t = (w_i，w_i{}^a，w_i{}^b)$作为 GRU 模型的输入，获取第 t 个词的 GRU 各个门单元状态的特征值如下：

$$\text{更新门：} z_t = \sigma(W_z \cdot [h_{t-1}，x_t] + b_z) \tag{4-10}$$

$$\text{重置门：} r_t = \sigma(W_r \cdot [h_{t-1}，x_t] + b_r) \tag{4-11}$$

$$\text{隐藏状态：} \tilde{h}_t = \tanh(W \cdot [r_t * h_{t-1}，x_t] + b_{\tilde{h}} \tag{4-12}$$

输出状态：$h_t = (1 - z_t) * h_{t-1} + z_t * \tilde{h}_t$ （4-13）

其中，W 为权重矩阵，b 为偏置向量，通过训练学习得到的参数；[]表示向量相连接，*表示矩阵元素相乘。

通过双向 GRU 编码可以获取第 t 个词语的输出状态，假设正向输出状态为$\overrightarrow{h_t}$，反向输出状态为$\overleftarrow{h_t}$，$h_t = \overrightarrow{h_t} \oplus \overleftarrow{h_t}$则充分表达了句子单个词语的高维语义信息。

4.2.3 引入实体上下文的词语层注意力

在关系抽取任务中，从对句子的理解与分析来看，并不是所有词语对句子语义有着相同的重要性，句子的上下文词语对于不同实体的影响程度是不一样的。例如，在句子“The United States President Trump will attend the NATO summit in Brussels, the capital of Belgium”中，词语“President”对于实体对<United States，Trump>比词语“capital”更重要，相反，在实体对<Brussels，Belgium>中，“capital”比“President”更重要。而注意力机制的基本思想是为每个不同的下层表示赋予一个重要性的权值，然后将每个表示与其所对应的权重的乘积进行重新组合。因此，本节将通过计算上下文词语和实体对之间的相关程度，建立词语层的注意力机制来充分捕捉句子上下文的语义信息。基于实体上下文的词语层注意力的计算方式如图 4-7 所示：

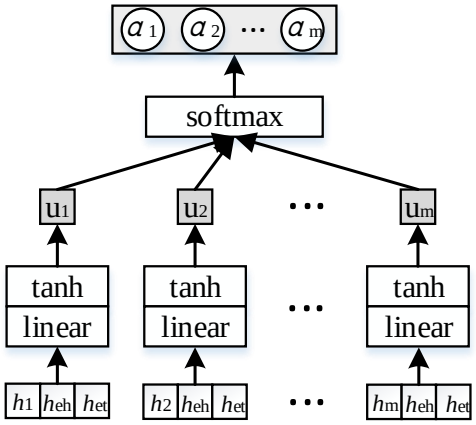

图 4-7　实体上下文的词语层注意力机制

假设由 BGRU 编码得到的句子向量表示$\mathrm{H} = \{h_1, h_2, \cdots, h_m\}$ 和实体对表示$< h_{eh}，h_{et} >$，通过计算句子中上下文词语与实体对的相关程度获取句子的向量表示x：

$$x = \sum_{i=1}^{m} \alpha_i h_i \tag{4-14}$$

其中，m 为句子长度，$\alpha_i \in [0,1]$为上下文词语相对于实体对的权重，且$\sum_i \alpha_i = 1$。这里使用一个前馈神经网络来计算不同词语与实体对的语义相关性，评分函数计算如下：

$$\mu_i = tanh(W_{word-att}[h_i, h_{eh}, h_{et}] + b_{word-att}) \tag{4-15}$$

其中，$W_{word-att}$为词语相关性权重矩阵，$b_{word-att}$为偏置值。然后通过 softmax 函数将计算得到的μ_1 ,μ_2 ,$\cdots \mu_m$进行归一化，从而得到权重α_i：

$$\alpha_i = \frac{exp(\mu_i)}{\sum_k^m exp(\mu_k)} \tag{4-16}$$

最后，在池化层选用最大池化方式获取句子中最关键的特征信息，句子的向量表示如下：

$$s = maxpool(x) \tag{4-17}$$

4.2.4 引入实例置信度的句子层注意力

为了减少传统远程监督关系抽取带来的噪声标注问题，本小节采用与文献[39]相同的句子层注意力机制进行多实例学习，通过计算含有相同实体对所有句子与关系标签的相关程度，赋予句子实例不同权值。如果句子与关系标签相关程度越高，那么对应句子的权值也就越高，降低噪声句子对关系预测的影响。

假设含相同实体对的 k 个句子组成的句子集$S = \{s_1, s_2, \cdots s_k\}$，为了能够突出所有句子与预测关系的相关程度，可以将句子向量表示为S中所有句子向量的加权和形式：

$$\mathrm{R} = \sum_{i=1}^{k} \beta_i s_i \tag{4-18}$$

其中，$\beta_i \in [0,1]$为句子集中每个句子相对于关系标签的权值，且$\sum_i \beta_i = 1$。通过计算句子向量和关系向量之间的内积，获得句子层的注意力权值β_i，并使用 softmax 函数进行归一化：

$$\beta_i = softmax(s_i A v_r) \tag{4-19}$$

其中，A为随机初始化的加权对角矩阵，v_r为关系 r 的向量表示。

4.2.5 引入依存关系的关系层注意力

实体关系抽取任务中，在对关系类型进行判别和预测时，不同的关系类型之间可能存在依赖和蕴含的情况，通过全局考虑应该能够获得更好的关系预测结果。例如，关系三元组<Beijing，China，Capital Of>可以通过简单的隐含关系推断出三元组< Beijing，China，Part Of>，关系“Part Of”蕴含了关系“<Capital Of>”，这两种关系可以判别为同一种关系类型。因此，本节将充分利用关系标签之间的依存关系去学习更好的特定关系下的集合表示。

在上节句子实例置信度的计算过程中，针对每一种关系标签已经学习到一个相对于实体集合的表示向量。将这些关系集中在一起便得到关系向量集合$C = \{R_1, R_2 \cdots R_n\}$。为了能够充分利用不同关系标签之间的依存关系并将其运用到如何学习更好的关系向量，本节采用与上一节类似的注意力机制，将句子实例替换为关系标签，研究哪些关系能够帮助表达当前关系，进而学习到更上一层的关系向量，关系R_i可以通过其它关系进行加权表示为：

$$R_i{}^* = \sum_{j=1}^{n} \gamma_{ij} R_j \tag{4-20}$$

其中，$\gamma_{ij} \in [0,1]$表示关系R_i与关系R_j之间的相似性权重，且$\sum_j^n \gamma_{ij} = 1$。通过关系R_i与关系R_j的向量内积计算γ_{ij}，即

$$\gamma_{ij} = softmax(R_i B R_j) \tag{4-21}$$

其中，B为加权对角矩阵。

4.2.6 模型训练与优化

将多层注意力机制输出的关系表示$\{R_1^*, R_2^*, \cdots R_n^*\}$，通过线性表示得到每种关系的正确分类：

$$o_i = W_i R_i^* + b_i \tag{4-22}$$

其中，W_i是每个关系标签的权重矩阵，b_i为偏移向量。然后再通过 sigmoid 逻辑函数，预测每种关系的条件概率：

$$p(i|M, \theta) = \frac{1}{1+exp(-o_i)} \tag{4-23}$$

其中，M为对齐句子集合，$\mathrm{i} \in (1,2,\cdots \mathrm{k})$，k为关系的数量。

为了获取多标签分类的最优模型，本章将采用交叉熵损失函数作为目标函数，定义如下：

$$J(\theta) = -\sum_{i=1}^{k} log\, p(i|M,\theta) \tag{4-24}$$

其中，θ表示模型可训练参数，通过反向传播计算所有参数的梯度，并使用Adadelta 优化器进行参数更新。

为了防止出现过拟合现象，以及提高模型的训练速度，本章还将采用Dropout[52]对关系抽取模型进行正则化约束。Dropout 将主要用在双向 BGRU 编码层，在保持输入输出神经元不变的前提下，随机地丢弃隐藏层的部分神经元。

4.3 实验准备

4.3.1 数据集与评估标准

数据集：由于第三章获取的标注数据集的关系类型只有十种且句子数量较少，不适合用来评估本章提出的多层次注意力机制关系抽取模型的效果。因此，本章将选用目前被广泛用于远程监督关系抽取任务上的 FreeBase +NYT 数据集，该数据集是由 Riedel 等人[34]在 2010 年通过将 Freebase 知识库中的实体对与纽约时报语料库（NYT）进行启发式对齐得到的。本章将 2005 至 2006年语料库对齐句子用做训练数据，2007 年语料库对齐句子用做测试数据，该数据集包含特殊关系 NA（即实体对无关系）在内，共有 53 种关系；训练集包含 522611 个句子，281270 个实体对，18252 个关系事实；测试集包含 172448 个句子，96678 个实体对，1950 个关系事实。

评估标准：本章主要采用准确率-召回率（PR）曲线、F 值（F_score）和平均准确率（P@N）作为评价指标，来评估提出多层注意力关系抽取模型是否有效。准确率、召回率和 F 值的计算方法同公式（3-10）、（3-11）和（3-12）。

4.3.2 实验环境与参数设置

实验环境：操作系统 Windows10，64 位；处理器 Intel(R) Xeon(R) CPU E3-1225 v5@3.30GHz；内存 16G；编程平台 Pycharm，Python3.6 版本。

参数设置：本章采用交叉验证方法对模型参数进行调优，在参数设置过程中，参照文献[39]的经验，并通过实验验证，具体参数设置如下表：

表 4-1 实验参数设置

参数	值
词向量维度d_w	50
位置向量维度d_{ab}	5
句子向量维度d_s	230
关系向量维度d_r	230
学习率μ	0.001
批大小B	60
Dropout 率ρ	0.5

4.4 实验设计及结果分析

4.4.1 当前主流方法对比

本章将提出的多层次注意力机制方法（简称为 BGRU+3ATT）与当前具有代表性的远程监督关系抽取方法进行比较：

基于特征的传统远程监督方法：（1）Mintz 方法： Mintz 等人[33]首次提出的远程监督方法，采用多类逻辑回归分类器进行分类；（2）Hoffmann 方法：Hoffmann 等人[35]提出的一种基于“at-least-one”确定性假设的多实例学习方法；（3）MIML 方法：Surdean 等人[36]提出的一种采用图模型进行远程监督的多实例多标签方法。

基于神经网络的远程监督方法：（1）PCNN+MIL：Zeng 等人[38]采用的分段最大池的卷积神经网络并结合多实例学习的远程监督方法；（2）PCNN+ATT：Liu 等人[39]在 Zeng 的基础上引入句子层注意力机制减少噪声标注的方法。

将以上五种方法与本文提出的方法进行对比，实验结果所绘出的准确率-召回率（PR）曲线如图 4-8 所示：

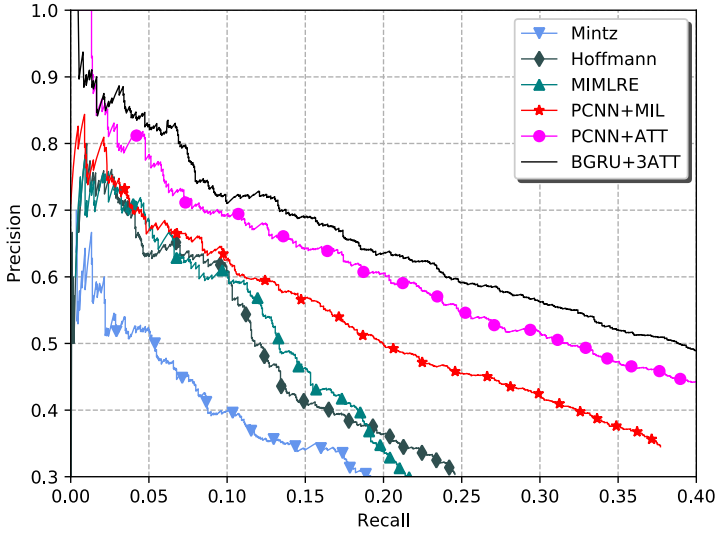

图 4-8 不同方法的 PR 曲线

从 PR 曲线可以看出，基于神经网络的方法明显优于基于特征的传统方法，主要原因是神经网络模型能够自动学习句子特征，从而避免了特征选择和 NLP 工具带来的错误传播问题；相较于其他神经网络方法，本文提出的多层次注意力机制方法有着较高的准确率和召回率，比 PCNN+ATT 模型提高了 4%~5%，说明了在 BGRU 模型上引入词语层、句子层和关系层注意力机制对提高远程监督关系抽取效果有一定的积极作用。

4.4.2 不同注意力机制对模型的影响

多层次注意力机制是该关系抽取模型的最重要部分，该实验部分将采用注意力增量的方法，分别在 BGRU 模型的基础上引入不同层次的注意力机制，从而验证词语层、句子层和关系层的注意力机制对模型的影响效果，同样使用准确率-召回率（PR）曲线进行评估，实验结果如图 4-9 所示：

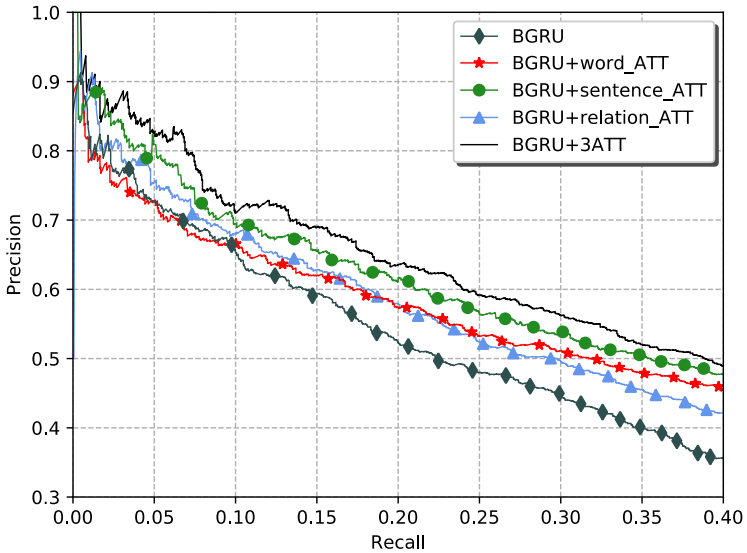

图 4-9 不同层次的注意力机制对模型的影响

从上图可以看出，在 BGRU 模型的基础上分别引入不同层次的注意力机制后的准确率，相较于单纯的 BGRU 关系抽取模型都有了进一步的提升，从而验证了在模型中增加词语层、句子层和关系层的注意力机制对关系抽取效果具有一定的促进作用；同时，句子层注意力对模型的影响程度要比其他两种注意力机制略高一点，主要原因是句子层的选择注意力能够充分考虑到包中所有句子的全局信息；而相比于 BGRU+3ATT，多层注意力机制方法优于其它单层注意力机制方法，说明 BGRU+3ATT 能够融合多层注意力机制，取长补短，相互促进，提高远程监督关系的抽取效果。

为了进一步验证关系层注意力对于语料句子中依赖包含关系的影响，该实验部分还选取了已知关系语料中具有依赖包含关系的两组种子关系（/people/person/children 和 /people/family/members，以及/location/location/contain 和/location/country/ capital），然后采用 BGRU 和$\mathrm{BGRU+ATT}_{relation}$模型进行对比实验，并采用 F 值进行评估，实验结果如表 4-2 所示：

表 4-2 关系层注意力对依赖关系的影响

关系	BGRU	$BGRU + ATT_{relation}$
/people/person/children	56.24%	59.13%
/people/family/members	54.91%	58.68%
/location/location/contain	59.6%	65.21%
/location/country/capital	61.35%	64.46%

从表 4-2 可以看出，引入关系层注意力提高了依赖包含关系的抽取效果，并且依赖关系都具有相似的 F 值，其主要原因是依赖包含关系具有相似的关系表示，可以判断为同一类关系，降低了关系分类过程中的误差。

4.4.3 不同句子数量对模型的影响

在原始测试数据集中，有 74857 个实体对仅对应一个句子，几乎是所有实体对的 3/4。由于句子层和关系层注意力机制的优势在于包含多个句子的实体对，因此，该实验部分将采用平均准确率 P@N 评估各模型对含有多个句子的实体对的关系抽取性能。（注：词语层注意力机制目的在于获取句子的高层语义信息，与包含实体对的句子数量关系不大，这里不做对比。）

表 4-3 包含实体对的不同句子数量平均准确率 P@N

P@N(%) 测试集 / 模型	One				Two				All			
	100	200	300	Mean	100	200	300	Mean	100	200	300	Mean
BGRU	69.9	66.7	61.1	65.9	71.4	69.6	61.8	67.6	72.2	68.8	64.4	68.5
$BGRU + ATT_{sentence}$	74.7	70.8	63.9	69.8	76.6	73.9	67.4	72.6	76.5	74.6	70.2	73.8
$BGRU + ATT_{ralation}$	72.3	67.5	62.6	67.5	74.7	69.1	66.5	70.1	75.3	71.4	67.8	71.5
PCNN + ATT	73.3	69.2	60.8	67.8	77.2	71.6	66.1	71.6	76.2	73.1	67.4	72.2
BGRU + 3ATT	79.2	73.1	66.4	72.9	80.3	75.9	71.6	75.9	82.6	77.7	72.5	77.6

实验结果如表 4-3 所示：（1）相较于基准方法 PCNN +ATT，BGRU+3ATT 方法比 PCNN+ATT 的 P@N 值提高了 5%左右，再次验证了多层次注意力机制对远程监督关系抽取的有效性；（2）相较于单纯的 BGRU 方法，BGRU + $ATT_{sentence}$和BGRU + $ATT_{relation}$方法的 P@N 值都有了较明显的提高，证明了句子层和关系层的注意力机制对多实例学习的促进作用，同时句子层注意力机制对关系抽取的促进效果也要高于关系层注意力机制。

4.5 本章小结

本章主要阐述了引入注意力机制对远程监督关系抽取任务的影响，首先介绍了注意力机制的相关理论，简要地描述了注意力机制近年来在图像领域和自然语言领域的发展历程，以及在端对端的序列模型中引入注意力机制的方法过程；然后以 PCNN+ATT 模型为例介绍了远程监督关系抽取模型中引入句子层注意力机制，以降低噪声标注数据。

鉴于 PCNN+ATT 模型的思想，本章提出了融合多层次注意力机制的远程监督关系抽取，分别在词语层、句子层以及关系层采用了注意力机制，词语层注意力能够充分获取句子上下文的高层语义信息，句子层注意力能够减少标签的错误标注问题，而关系层注意力则能够自动学习不同关系之间的依赖包含关系。将三层注意力机制进行融合、协同训练，在公共真实数据集上的实验结果表明，本文提出的方法相较于现有方法有了较大的进步。

第 5 章 总结与展望

5.1 总结

实体关系抽取作为信息抽取的主要任务之一，为构建知识图谱、开放域问答等应用奠定了坚实的理论基础。针对实体关系抽取中标注语料严重缺乏的问题，本文采用远程监督的方法进行实体关系抽取，主要的工作内容包括以下几点：

（1）对基于远程监督的实体关系抽取方法进行详细的分析，首先对远程监督关系抽取的原理进行整理归纳，然后分别从启发式对齐、特征提取、训练分类器以及关系抽取四个步骤介绍了远程监督关系方法的流程，最后结合具体的实例分析了远程监督关系抽取方法存在的噪声标注问题，以及目前常用的相关降噪方法。

（2）针对远程监督关系抽取方法存在大量噪声标注数据，本文提出了一种基于语义相似度的噪声标注过滤方法。该方法通过基于词向量的 Jaccard 相似性度量方法计算最短依存路径上的短语与关系短语之间的语义相似度来判断原始数据是否被正确标注，语义相似度越高，正确标注的概率越高，最后将过滤后的标注数据输入到 PCNN 关系抽取模型中进行关系分类。实验表明，本文提出的降噪方法能够明显提高远程监督方法的关系抽取效果。

（3）为了充分结合深度学习技术生成一体化程度较高的远程监督关系抽取模型，进一步提高实体关系的抽取效果，本文提出了一种融合多层次注意力机制的远程监督关系抽取模型。该模型首先通过双向 GRU 神经网络对句子词向量进行编码来获取句子高维语义；其次通过引入词语层注意力来计算两个实体与上下文词语的相关程度，从而充分捕捉句子中实体上下文的语义信息；然后在多个实例上构建句子层的注意力来减少标签错误标注的问题；最后通过关系层的注意力自动学习不同关系之间的依赖包含关系。在公共数据集上的实验表明，本文提出的模型相较于当前主流的远程监督关系抽取模型在准确率-召回率曲线上有了 4%左右的提高，更加有效地实现了实体关系抽取。

5.2 工作期望

本文采用基于远程监督的方法进行了实体关系抽取的研究，并取得了一定的成果。但是，该研究仍然存在一些问题和不足有待完善，主要表现在以下几个方面：

（1）在基于语义相似度的噪声标注过滤方法中，为确定最优相似度阈值 δ，本文只取区间[0,0.9]间隔为0.1的相似度进行实验，最优相似度阈值δ不够精确，实验中的相似度区间还可以细化，后期有待进一步改善。

（2）在融合多层次注意力机制的远程监督关系抽取模型中，本文采用的 GRU 神经网络对句子进行编码，虽然在一定程度上解决了句子的长距离依赖问题，但在捕获句子局部关键特征时，其性能不及 CNN 网络。在后期工作中，将打算尝试将 GRU 与 CNN 进行结合来表征句子向量，以获取更加丰富的特征。

（3）远程监督关系抽取方法虽然能够缓解标注语料缺乏的问题，但是该方法过度依赖于知识库，知识库的质量直接决定了标注数据的质量。同时，该方法不能发现知识库以外的关系类型，限制了关系抽取的范围。后期将结合知识融合和知识推理相关理论，实现关系的推理和预测，进一步发现隐藏的关系信息。

致谢

时间如白驹过隙，三年的研究生生涯即将落下帷幕，毕业之期已然到来。马上就要离开大学校园了，内心感慨万分，久久不能平静。回顾这三年生活的点点滴滴，充满了苦涩和艰辛，但更多的是快乐和喜悦。三年来，我收获的不仅仅只有专业知识，还有周围老师和同学们带给我的感动。在论文即将完成之际，我要向那些曾经给予我帮助、支持和关怀的人表达最真挚的感谢。

首先，我要感谢我的导师刘永坚老师。刘老师为人和蔼，治学严谨，对学生认真负责，指导有方。在研究生学习期间，刘老师不仅在学术科研上给我提供了很好的学习成长环境，让我的学习能力和科研能力得到了全面的锻炼和提高，而且在日常生活上给予我无微不至的关怀。刘老师的谆谆教诲我将终身铭记，对于我未来的人生规划将获益匪浅。同时，也要感谢我的指导老师解庆老师，感谢解老师在学术研究上给我的点拨和帮助。在论文的选题、研究和写作过程中，解老师给我提供了许多宝贵的修改意见。解老师严谨的科研态度和创新的科研精神都是我永远学习的目标。

其次，我要感谢数字传播实验室的师兄师姐师弟师妹们，感谢大家共同营造出一个良好的学习环境和科研氛围。无论在生活上还是学习上，我们朝夕相处，互帮互助，在我遇到困难的时候，他们都会给予我莫大的帮助。正是他们的陪伴，让我度过了这三年充实而美好的时光。

然后，我要特别感谢我的父母。感谢父母二十多年来对我的精心培育，他们一如既往的关心和支持是我不断前进的动力，也是我坚强的后盾，激励着我乘风破浪，勇往直前。这一切我都将没齿难忘，将来必定加倍报答他们的养育之恩。

最后，向参与论文评审和答辩的各位老师致以诚挚的谢意，感谢各位老师在百忙之中对我的论文进行细心审阅。

参考文献

[1] Gabor K, Buscaldi D, Schumann A, et al. SemEval-2018 Task 7: Semantic Relation Extraction and Classification in Scientific Papers[C]. North American Chapter of the Association for Computational Linguistics, 2018: 679-688.

[2] 刘绍毓，李弼程，郭志刚,等. 实体关系抽取研究综述[J]. 信息工程大学学报，2016, 17(5):541-547.

[3] Miller S，Fox H，Ramshaw L，et al．A Novel Use of Statistical Parsing to Extract Information from Text[C]. Proceedings of the 1st North American Chapter of the Association for Computational Linguistics Conference．2000: 226-233.

[4] Shen W, Doan A H, Naughton J F, et al. Declarative Information Extraction Using Datalog with Embedded Extraction Predicates[C]. Proceedings of the 33rd International Conference on Very Large Data Bases. 2007:1033-1044.

[5] Kambhatla N. Combining Lexical, Syntactic and Semantic Features with Maximum Entropy Models for Extracting Relations[C]. Proceedings of the ACL 2004 on Interactive Poster and Demonstration Sessions. 2004:22-es.

[6] Tratz S, Hovy E. ISI: Automatic Classification of Relations between Nominals Using a Maximum Entropy Classifier[C]. Proceedings of the 5th International Workshop on Semantic Evaluation. Association for Computational Linguistics, 2010:222-225.

[7] 甘丽新，万常选，刘德喜，等. 基于句法语义特征的中文实体关系抽取[J]. 计算机研究与发展, 2016, 53(2):284-302.

[8] Zelenko D, Aone C, Richardella A. Kernel Methods for Relation Extraction[J]. Journal of Machine Learning Research, 2003, 3(3):1083-1106.

[9] Culotta A, Sorensen J S. Dependency Tree Kernels for Relation Extraction[C]. Meeting of the Association for Computational Linguistics, 2004: 423-429.

[10] Bunescu R, Mooney R. A Shortest Path Dependency Kernel for Relation Extraction[C]. Conference on Human Language Technology & Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2005: 724-731.

[11] Mooney R J, Bunescu R C. Subsequence Kernels for Relation Extraction[C]. International Conference on Neural Information Processing Systems. MIT Press, 2005: 171-178.

[12] 黄晨，钱龙华，周国栋，等. 基于卷积树核的无指导中文实体关系抽取研究[J]. 中文信息学报, 2010, 24(4):11-18.

[13] 李枫林，柯佳. 基于深度学习框架的实体关系抽取研究进展[J]. 情报科学，2018, V36(3):169-176.

[14] Hassan A, Mahmood A. Convolutional Recurrent Deep Learning Model for Sentence Classification[J]. IEEE Access, 2018: 13949-13957.

[15] 喻丽. 基于卷积神经网络的中文自动文摘方法[D]. 哈尔滨: 哈尔滨工业大学, 2016.

[16] Poria S, Peng H, Hussain A, et al. Ensemble Application of Convolutional Neural Networks and Multiple Kernel Learning for Multimodal Sentiment Analysis[J]. Neurocomputing, 2017, (261): 217-230.

[17] Liu C Y, Sun W B, Chao W H, et al. Convolution Neural Network for Relation Extraction[C]. International Conference on Advanced Data Mining and Applications. Springer, Berlin, Heidelberg, 2013: 231-242.

[18] Nguyen T H, Grishman R. Relation Extraction: Perspective from Convolutional Neural Networks[C]. Workshop on Vector Space Modeling for Natural Language Processing. 2015: 39-48.

[19] 王林玉，王莉，郑婷一. 基于卷积神经网络和关键词策略的实体关系抽取方法[J]. 模式识别与人工智能, 2017,30(5):465-472.

[20] Luo Y. Recurrent Neural Networks for Classifying Relations in Clinical Notes[J]. Journal of Biomedical Informatics, 2017: 85-95.

[21] Sundermeyer M, Schluter R, Ney H. LSTM Neural Networks for Language Modeling[C]. Thirteenth Annual Conference of the International Speech Communication Association, 2012: 194-197.

[22] Banerjee S, Tsioutsiouliklis K. Relation Extraction Using Multi-Encoder LSTM Network on a Distant Supervised Dataset[C]. 2018 IEEE 12th International Conference on Semantic Computing (ICSC). IEEE, 2018: 235-238.

[23] 王红，史金钏，张志伟. 基于注意力机制的 LSTM 的语义关系抽取[J]. 计算机应用研究, 2018(5):1417-1421.

[24] Brin S. Extracting Patterns and Relations from the World Wide Web[C]. International Workshop on the World Wide Web & Databases. 1998.

[25] Agichtein E, Gravano L. Snowball: Extracting Relations from Large Plain-Text Collections[C]. Proceedings of the Fifth ACM International Conference on Digital Libraries, 2000: 85-94.

[26] Liu X, Yu N. Multi-Type Web Relation Extraction Based on Bootstrapping [C]. Proceedings of WASE International Conference on Information Engineering, 2010: 24-27.

[27] 何婷婷，徐超，李晶，等. 基于种子自扩展的命名实体关系抽取方法[J]. 计算机工程, 2006, 32(21):183-184.

[28] Cvitas. Relation Extraction from Text Documents[C]. Mipro, International Convention. IEEE, 2011:1565-1570.

[29] Hasegawa T, Sekine S, Grishman R．Discovering Relations among Named Entities from Large Corpora[C]. Proceedings of the 42nd Annual Meeting on Association for Computational Linguistics, 2004: 415-422.

[30] Zhang M, Su J, Wang D, et al. Discovering Relations between Named Entities from A Large Raw Corpus using Tree Similarity-based Clustering [M]. Natural Language Processing-IJCNLP 2005. Springer, 2005:378-389.

[31] Quan C, Wang M, Ren F. An Unsupervised Text Mining Method for Relation Extraction from Biomedical Literature[J]. PLoS ONE, 2014, 9(7).

[32] 孙勇亮. 开放领域的中文实体无监督关系抽取[D].上海：华东师范大学，2014.

[33] Mintz M, Bills S, Snow R, et al. Distant Supervision for Relation Extraction without Labeled Data[C]. InternationalJoint Conference on Natural Language Processing, 2009: 1003-1011.

[34] Riedel S, Yao L, Mccallum A. Modeling Relations and Their Mentions without Labeled Text [J].Machine Learning and Knowledge Discovery in Databases.2010:148-163.

[35] Hoffmann R, Zhang C, Ling X, et al. Knowledge-based Weak Supervision for Information Extraction of Overlapping Relations[C]. Proceedings of the Association for Computational Linguistics: Human Language Technologies. Stroudsburg: Association for Computational Linguistics.2011: 541-550.

[36] Surdeanu M, Tibshirani J, Nallapati R, et al. Multi-instance Multi-label Learning for Relation Extraction [C]. Proceedings of Joint Conference on Empirical Methods in Natural Language Processing and Computational Natural Language Learning. 2012: 455-465.

[37] Benjamin R, Dietrich K. Combining Generative and Discriminative Model Scores for Distant Supervision[C]. Proceedings of the 2013 Conference on Empirical Methods in Natural Language Processing. 2013: 24-29.

[38] Zeng D, Liu K, Chen Y, et al. Distant Supervision for Relation Extraction via Piecewise Convolutional Neural Networks[C]. Proceedings of Conference on Empirical Methods in Natural Language Processing. 2015:1753-1762.

[39] Lin Y, Shen S, Liu Z, et al. Neural Relation Extraction with Selective Attention over Instances [C]. Proceedings of Meeting of the Association for Computational Linguistics. 2016: 2124-2133.

[40] Ji G, Liu K, He S, et al. Distant Supervision for Relation Extraction with Sentence-level Attention and Entity Descriptions[C]. Proceedings of the Thirty-First AAAI Conference on Artificial Intelligence. 2017: 3060-3066.

[41] Lei K, Chen D, Li Y, et al. Cooperative Denoising for Distantly Supervised Relation Extraction [C]. Proceedings of the 27th International Conference on Computational Linguistics. 2018: 426-436.

[42] Feng J, Huang M, Zhao L, et al. Reinforcement Learning for Relation Classification from Noisy Data[C]. The Thirty-Second AAAI Conference on Artificial Intelligence. 2018:5779-5786.

[43] Roth B, Klakow D. Feature-based Models for Improving the Quality of Noisy Training Data for Relation Extraction[C]. Proceedings of the 22nd ACM International Conference on Information & Knowledge Management. ACM, 2013:1181-1184.

[44] Takamatsu S, Sato I, Nakagawa H. Reducing Wrong Labels in Distant Supervision for Relation Extraction[C]. Meeting of the Association for Computational Linguistics, 2012: 721-729.

[45] Bunescu R, Mooney R. A Shortest Path Dependency Kernel for Relation Extraction[C]. Proceedings of Conference on Human Language Technology and Empirical Methods in Natural Language Processing. Association for Computational Linguistics, 2005:724-731.

[46] Zhang X, Sun S, Zhang K. An information Content-Based Approach for Measuring Concept Semantic Similarity in WordNet[J]. Wireless Personal Communications, 2018:117-132.

[47] 张硕望, 欧阳纯萍, 阳小华, 等. 融合《知网》和搜索引擎的词汇语义相似度计算[J]. 计算机应用, 2017, 37(4):1056-1060.

[48] Mikolov T, Chen K, Corrado G, et al. Efficient Estimation of Word Representations in Vector Space[J]. Computer Science, 2013.

[49] Mnih V, Heess N, Graves A, et al. Recurrent Models of Visual Attention[J]. Neural Information Processing Systems, 2014: 2204-2212.

[50] Bahdanau D, Cho K, Bengio Y, et al. Neural Machine Translation by Jointly Learning to Align and Translate[J]. International Conference on Learning Representations, 2015.

[51] Chung J, Gulcehre C, Cho K, et al. Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling[J]. arXiv: Neural and Evolutionary Computing, 2014.

[52] Hinton G E, Srivastava N, Krizhevsky A, et al. Improving Neural Networks by Preventing Co-adaptation of Feature Detectors[J]. Computer Science, 2012, 3(4): 212-223.

攻读学位期间获得与学位论文相关的科研成果

[1] 李浩, 刘永坚, 解庆, 等. 基于多层次注意力机制的远程监督关系抽取模型[J]. 计算机科学, 2018.